MOBILEWIKI

온디바이스 문서 AI 학습 시리즈

과목 1 / 개념과 실습

AI와 머신러닝 기본 개념

개념을 읽고, 예제로 이해하고, 직접 실습합니다.

01 개념

02 예제

03 실습

이 책에서 다루는 내용

1. 이 과목에서 할 수 있게 될 일
2. AI에게 어떤 글을 주고, 어떤 결과를 받을까요?
3. AI와 머신러닝과 딥러닝

차례

학습 순서에 따라 읽거나, 항목을 눌러 해당 페이지로 이동하세요.

1. 이 과목에서 할 수 있게 될 일 3

2. AI에게 어떤 글을 주고, 어떤 결과를 받을까요? 3

3. AI와 머신러닝과 딥러닝 6

4. 데이터와 모델을 구분하기 9

5. 학습과 추론은 언제 일어날까요 12

6. 분류와 두 가지 요약 방식 18

7. 실습 1 손으로 학습하고 추론하기 21

8. 실습 2 문서 30개에 라벨 붙이기 23

9. 실습 3 분류와 요약을 구분하기 28

10. 확인 문제 29

11. 실습과 확인 문제 해설 30

12. 선택 실습 Python으로 같은 점수표 만들기 34

13. 과목 1 완료 확인 36

이 자료는 AI를 처음 공부하는 비전공자를 위한 자료입니다. 문서 분류 · 군집화 · 요약을 예로 들어 AI와 머신러닝의 관계, 모델 · 학습 · 추론의 기본 원리를 익힙니다.

종이와 메모장만으로 필수 실습을 할 수 있습니다. 마지막의 Python 실습은 선택 사항이며, 별도 라이브러리나 GPU가 필요하지 않습니다.

전체 학습 순서는 학습 계획서에서 확인할 수 있습니다.

1. 이 과목에서 할 수 있게 될 일

이 과목의 목표는 용어 암기보다 다음 질문에 자신의 말로 답하는 것입니다.

- 모델 · 데이터 · 파라미터는 각각 무엇인가요?
- 학습과 추론은 어떻게 다른가요?
- 정답으로 배우는 분류와 정답 없이 묶는 군집화는 어떻게 다른가요?
- N개 그룹의 N과 그룹 번호는 각각 무엇을 뜻하나요?
- 문서 군집화와 두 가지 요약 방식은 어떻게 다른가요?
- 정답 기준이나 '비슷하다'는 기준이 모호하면 어떤 문제가 생기나요?
- 사전학습 · 추가학습 · 추론은 어떻게 다른가요?
- 학습 · 검증 · 최종 평가 자료는 왜 구분하나요?

2~6절을 읽고 7~9절을 실습하세요. 10절의 문제를 푼 뒤 11절 해설과 비교합니다. Python 실행은 12절의 선택 실습에서 다룹니다.

2. AI에게 어떤 글을 주고, 어떤 결과를 받을까요?

이 절의 목표는 'AI로 문서를 분석한다'는 말을 구체적인 일로 바꾸는 것입니다. 먼저 어떤 글을 줄지, 그 글에서 어떤 결과를 받고 싶은지 정합니다. 같은 글을 주어도 문서의 종류를 고르는 일과 내용을 짧게 줄이는 일은 서로 다릅니다.

2.1 입력은 AI에게 주는 글이고, 출력은 받고 싶은 결과입니다

다음 글을 AI에게 준다고 생각해 봅시다. 이 글과 아래의 결과는 모두 학습을 위해 만든 예제입니다.

> 새 스마트폰에 배터리 절약 기능이 추가됐다. 이 기능을 켜면 화면 밝기가 자동으로 낮아진다. 설정 화면의 아이콘도 바뀌었다.

이 원문이 입력입니다. 원하는 작업을 정한 뒤 얻는 결과를 출력이라고 합니다. 아래는 같은 원문에 서로 다른 작업을 적용한 예입니다.

하고 싶은 일	작업 이름	출력 예시
IT·경제·스포츠 중 이 글의 종류를 고른다	문서 분류	IT
배터리 기능의 핵심을 설명하는 원문 문장을 고른다	추출 요약	새 스마트폰에 배터리 절약 기능이 추가됐다. 이 기능을 켜면 화면 밝기가 자동으로 낮아진다.
배터리 기능의 핵심을 새로운 한 문장으로 줄인다	생성형 요약	새 스마트폰에 화면 밝기를 자동으로 낮추는 배터리 절약 기능이 추가됐다.

'IT' 라는 이름을 받아도 원문의 핵심 내용을 읽을 수는 없습니다. 반대로 짧은 요약문을 받는 것은 종류 이름 하나를 고르는 일과 다릅니다. 그래서 **원하는 출력이 무엇인지 먼저 정해야 필요한 모델과 평가 방법을 고를 수 있습니다.** 모델은 입력에서 결과를 계산하도록 만든 것입니다. 이 표는 작업별 결과를 비교한 것이며, 하나의 모델이 모든 결과를 자동으로 함께 제공한다는 뜻은 아닙니다.

2.2 문서 여러 개를 비슷한 내용끼리 모으는 일도 있습니다

이번에는 위 원문을 문서 A라고 하고, 두 문서를 더 가져옵니다. 아래는 이 세 문서를 내용에 따라 두 그룹으로 묶은 한 예입니다.

문서	내용
A	위의 스마트폰 배터리 절약 기능 소개
B	휴대폰에서 배터리를 아끼는 설정을 소개한다.
C	축구팀이 결승전에서 우승했다.

그룹	함께 묶인 문서	내용상 공통점
0	A와 B	휴대폰 배터리 기능·설정
1	C	축구 경기 소식

이처럼 여러 문서 사이의 비슷함을 비교해 묶는 작업이 군집화입니다. 여기서는 정답 주제 이름을 먼저 주지 않았습니다. 사람이 묶인 내용을 읽고 그룹 0의 이름을 휴대폰 배터리로 정할 수 있습니다. 그룹 번호 자체가 주제 이름을 뜻하지는 않습니다. 위 묶음은 이해를 돕는 예이며, 실제 모델이 언제나 이렇게 묶는다는 보장은 없습니다.

분류의 출력은 정해진 종류 중 하나이고, 군집화의 결과는 문서들이 어느 그룹에 함께 묶였는지입니다. 따라서 군집화에서는 비교할 문서 모음이 필요합니다. '새 글의 종류를 맞히기'와 '문서 모음을 비슷한 것끼리 나누기'를 구분해 두세요. 실제 군집화 방법과 새 문서의 그룹 배정은 뒤의 Chapter에서 배웁니다.

2.3 컴퓨터가 글을 처리하려면 숫자로 바꾸어 계산합니다

사람은 글을 읽지만, 컴퓨터의 모델은 계산할 수 있는 숫자를 사용합니다. 그래서 문서 입력 → 숫자로 표현 → 모델 계산 → 결과의 흐름이 필요합니다. 분류 · 군집화 · 요약은 원하는 결과가 다르므로, 사용하는 숫자 표현과 계산도 달라질 수 있습니다.

계산 과정을 쉽게 보려고 입력을 '배터리 수명 안내'라는 짧은 글로 바꿔 봅시다. 이미 학습한 단어 점수가 배터리 +1, 경기 -2라고 가정합니다. 합계가 양수면 IT로 판단하는 작은 모델입니다.

1. 글을 준다: '배터리 수명 안내'를 입력한다.
2. 계산할 숫자로 바꾼다: 단어가 있으면 1, 없으면 0으로 표시한다. 이 글에는 배터리가 있고 경기는 없으므로, 이 순서로 쓴 숫자 목록은 [1, 0]이다.
3. 준비된 점수로 계산한다: 들어 있는 단어인 배터리의 점수 +1을 더한다. 경기는 없으므로 더하지 않는다. 합계는 +1이다.
4. 결과를 낸다: 합계가 양수이므로 IT를 출력한다.



그림 1. 하나의 입력에서 출력까지 이어지는 단어 점수 예제. 7절 모델의 일부 단어만 보여 주는 단순화이며, 실제 언어모델의 계산이나 품질을 나타내지는 않습니다.

여기서 한 일은 이미 준비된 점수로 결과를 계산한 것입니다. 글 하나를 처리했다고 점수를 새로 배우거나 바꾸지는 않았습니다. 그 점수를 자료에서 구하는 학습 과정은 7절에서 직접 해 봅니다. 실제 언어모델은 단어의 있음 · 없음만 보는 이 예제보다 복잡한 숫자 표현과 계산을 사용합니다.

확인해 보기: ‘이 글의 핵심을 한 문장으로 알려 줘’라는 작업에서 원하는 출력은 IT라는 이름일까요, 짧은 글일까요? 답은 짧은 글입니다. 이 차이를 설명하고, 군집화에는 비교할 여러 문서가 필요하다는 점을 말할 수 있으면 이 절의 목표를 이해한 것입니다. 파일에서 원문 텍스트를 읽는 방법은 Chapter 2에서 배웁니다.

3. AI와 머신러닝과 딥러닝

3.1 세 용어의 관계

AI는 넓은 분야의 이름이고, 머신러닝은 그 안의 한 접근법이며, 딥러닝은 머신러닝의 한 종류입니다.

용어	쉽게 이해하기	문서 분석에서의 예
AI 인공지능	판단·인식·언어 처리 같은 일을 컴퓨터로 수행하게 하는 넓은 분야	문서 내용을 분석하는 기능
ML 머신러닝	데이터에서 예측이나 패턴 탐색에 쓸 계산 기준을 얻는 방법	라벨로 문서 분류를 배우거나 비슷한 문서끼리 묶기
DL 딥러닝	여러 층으로 구성된 신경망을 학습하는 머신러닝 방식	사전학습 언어모델을 이용한 분류나 생성형 요약

AI · 머신러닝 · 딥러닝의 포함 관계

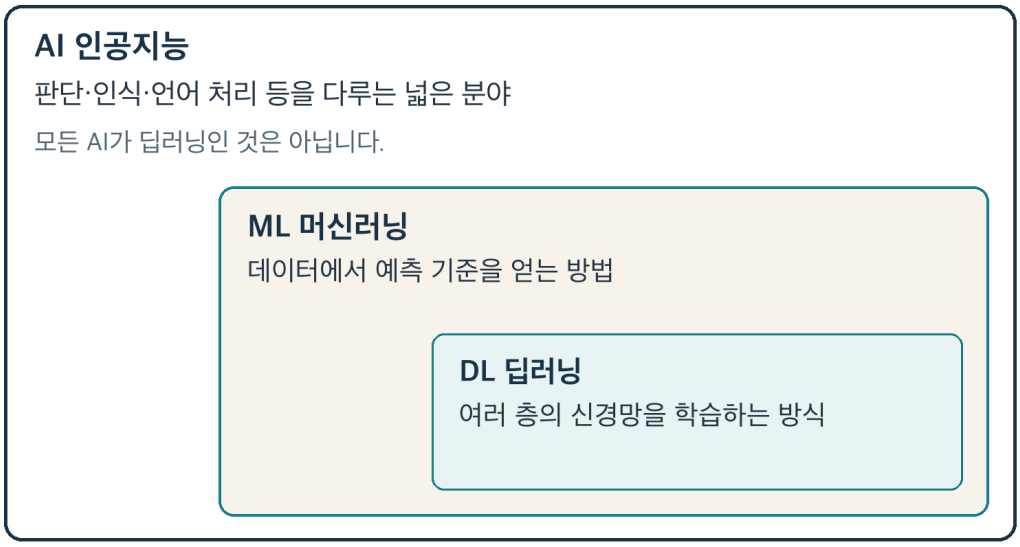


그림 2. AI, 머신러닝, 딥러닝의 포함 관계. 딥러닝은 AI를 구현하는 여러 방법 중 하나입니다.

신경망은 입력 숫자를 여러 계산 단계에 통과시켜 결과를 내는 모델입니다. 각 단계인 '층'은 앞 단계의 숫자를 계산해 다음 단계로 넘깁니다. 학습에서는 이 계산에 쓰는 숫자를 조정합니다. 뇌가 문장을 이해하는 과정을 그대로 재현한다는 뜻은 아닙니다. 실제 계산과 학습 원리는 Chapter 4에서 배웁니다.

표의 '사전학습 모델'은 많은 자료로 미리 학습해 둔 모델을 뜻합니다. 이를 내 작업에 활용하는 방법은 5.4절에서 비교합니다. 모든 문서 분류 문제에 큰 언어모델이 필요한 것은 아닙니다. 작은 머신러닝 모델도 분류에 사용할 수 있습니다.

3.2 사람이 규칙을 쓰는 방법과 데이터로 배우는 방법

개발자가 다음 규칙을 직접 만들 수 있습니다.

> 문서에 '축구'라는 글자가 있으면 스포츠로 분류한다.

이 규칙은 이해하고 수정하기 쉽습니다. 하지만 '축구 경기 기록을 관리하는 새 앱의 기능 소개' 도 스포츠로 분류할 수 있습니다. 앱 기능을 소개하는 문서라면 IT가 더 적절할 수 있습니다.

지도학습으로 분류기를 만들 때는 정답이 붙은 여러 문서로부터 단어와 주제의 관계 등을 계산합니다. 사람이 문서 하나하나의 모든 판단 규칙을 작성하는 대신, 데이터로부터 예측에 사용할 숫자를 얻습니다. 라벨 없이 문서 사이의 비슷함을 찾는 비지도학습도 있으며, 4.2절에서 비교합니다.

사람이 하는 일도 남아 있습니다. 무엇을 분류할지, 어떤 자료를 쓸지, 어떤 학습 방법으로 계산할지, 결과를 어떻게 평가할지는 사람이 설계합니다. 데이터로 배웠다고 문맥을 언제나 올바르게 구분하는 것은 아닙니다.

생각해 보기: 회사 규정의 특정 번호가 포함됐는지만 확인한다면 문자열 검색으로 충분할 수 있습니다. 여러 표현으로 쓰인 문서의 주제를 구분한다면 머신러닝을 검토할 이유가 생깁니다.

7절의 점수표 예제로 이 차이를 연결해 봅시다. 사람은 'IT 문서에 나온 단어에는 1을 더한다' 는 학습 절차를 정합니다. 그 절차로 문서와 정답을 계산하면 '배터리' 의 점수 1을 얻습니다. 이후 '배터리 수명 안내' 라는 새 문서에서는 이미 얻은 1을 읽어 IT로 예측합니다. 마지막으로 별도 정답과 비교해 맞았는지 확인합니다.

이 흐름은 **문서와 정답 → 학습으로 얻은 점수 → 새 문서의 예측 → 정답과 비교한 평가** 입니다. 사람이 직접 '배터리가 있으면 IT' 라는 최종 규칙을 적는 방식과 달리 점수 자체를 자료에서 구했습니다. 다만 사람이 학습 절차와 살펴볼 단어를 정한 매우 단순한 모델입니다. 데이터가 스스로 목적을 정하거나 모든 판단 방법을 만들어 내는 것은 아닙니다.

4. 데이터와 모델을 구분하기

4.1 입력과 라벨

지도학습 문서 분류에서 입력은 문서 내용이고, 라벨은 그 문서에 붙인 정답 종류입니다. 먼저 이 비교용 예제로 용어를 익힙니다.

입력 문서	라벨
새 스마트폰의 카메라 기능을 소개한다	IT
기업의 올해 매출과 영업이익을 발표한다	경제
축구 선수가 결승전에서 득점했다	스포츠

이렇게 정답을 붙인 예제로 배우는 방식을 **지도학습**이라고 합니다. 뒤의 점수표와 라벨링 실습은 지도학습의 기초를 이해하기 위한 것입니다. 최종 목표인 비지도 문서 군집화가 반드시 이 라벨로 학습해야 한다는 뜻은 아닙니다.

문서의 라벨은 문서가 가진 절대적인 속성이라기보다, 만들고 싶은 기능의 분류 기준에 따라 정해집니다. 예를 들어 IT 회사의 매출 기사도 '주요 내용이 실적이면 경제'라는 기준을 정했다면 경제가 됩니다.

4.2 지도학습과 비지도학습

지도학습 분류는 '정해진 이름을 맞히기', 비지도 군집화는 '비슷한 것끼리 모으기'로 생각하면 됩니다. 비지도학습은 정답 라벨 없이 데이터의 패턴을 찾는 방법이고, 군집화는 그 한 종류입니다.

방식	학습에 주는 것	결과의 의미
지도학습 분류	문서와 정답 라벨	정해진 종류 중 하나를 예측
비지도 군집화	정답 라벨이 없는 문서 모음	정한 유사성 기준에 따라 비슷한 문서를 같은 그룹으로 묶음

이번 목표의 N은 만들 그룹의 수입니다. 예를 들어 N=3이면 세 그룹으로 묶도록 정합니다. N을 3으로 정했다고 그 그룹이 자동으로 IT · 경제 · 스포츠가 되는 것은 아닙니

다. 모든 군집 방법이 그룹 수를 미리 요구하는 것도 아니지만, 이 과정에서는 N을 지정하는 방법부터 배웁니다.

군집 결과의 '그룹 0', '그룹 1' 같은 번호는 구별을 위한 표시입니다. 그룹 0이 항상 IT라는 뜻은 아니며, 다시 묶으면 번호나 구성도 달라질 수 있습니다. 사람은 결과를 본 뒤 각 그룹의 대표 문서와 핵심어를 검토하고 이름을 붙입니다. 이름은 내용을 설명하기 위한 것이지, 처음부터 학습에 넣은 정답이 아닙니다.

한국어 '배터리 절약 설정'과 영어 'battery-saving setting'은 표현이 달라도 비슷한 내용입니다. 최종 모델에서는 이러한 문서가 언어별로만 갈라지지 않고 내용에 따라 가까워지는지도 확인해야 합니다. 문서를 숫자로 표현하고 비슷함을 계산하는 방법은 뒤의 Chapter에서 배웁니다.

군집화에서 '비슷하다'는 기준은 중요합니다. 문서에 쓰인 언어만 비교하면 한국어 문서끼리 모일 수 있습니다. 반면 내용의 비슷함을 잘 표현하면 언어가 다른 배터리 문서도 함께 모을 수 있습니다. 정답 라벨이 없다는 것은 아무 기준 없이 묶는다는 뜻이 아닙니다. 사람이 고른 문서 표현과 비교 방법이 결과에 영향을 줍니다. 문서에 뚜렷한 주제 구분이 없으면 N개로 나눈 결과도 유용하지 않을 수 있습니다.

4.3 특성과 모델과 파라미터

컴퓨터는 텍스트를 계산 가능한 숫자로 바꿔 처리합니다. 모델이 판단에 사용하는 입력 정보를 **특성 feature**이라고 부릅니다. 단순한 예에서는 특정 단어가 있는지 여부가 특성이 될 수 있습니다.

모델은 입력에서 결과를 계산하는 구조와 그 구조에 들어가는 숫자를 포함합니다. 학습 과정에서 조정하거나 데이터로부터 구하는 숫자를 파라미터라고 합니다. 가중치는 파라미터의 한 종류입니다.

실습의 단어 점수는 자료에서 얻는 파라미터이지만, N=3처럼 사람이 정하는 그룹 수는 학습 · 계산 방법을 정할 때 선택하는 설정입니다.

뒤의 지도학습 비교 실습에서는 다음과 같은 작은 모델을 만듭니다.

구성	실습에서의 역할
특성	‘스마트폰’, ‘배터리’, ‘선수’, ‘경기’가 있는지
파라미터	각 단어에 붙는 점수
예측 계산	입력에 있는 단어들의 점수를 더하기
출력	IT, 스포츠 또는 판단 보류

실제 언어모델은 훨씬 많은 숫자와 복잡한 계산을 사용합니다. 그렇지만 입력을 계산에 넣어 결과를 얻는다는 큰 흐름은 같습니다.

문서 군집화에서도 내용을 숫자로 바꾸어 서로 비교할 수 있어야 합니다. 모델이 학습한 기준에 따라 문서 내용을 〔0.2, 0.7, …〕 같은 숫자 목록으로 표현한 것을 문서 임베딩 embedding이라고 부릅니다. 이런 숫자 목록을 벡터라고 하며, 문서를 임베딩으로 바꾸는 모델이 문서 표현 모델입니다. 각 숫자가 그대로 IT 점수나 정답 확률을 뜻하지는 않습니다.

내용이 비슷한 문서의 숫자 표현도 가깝게 나오도록 학습된 모델을 사용하면, 쓰인 단어가 달라도 비슷한 내용을 찾는 데 도움이 됩니다. 아래 숫자는 이 원리를 보여 주려고 직접 만든 설명용 좌표입니다. 실제 임베딩이나 성능 측정값은 아닙니다.

문서	언어와 내용	설명용 숫자 두 개
A	한국어: 배터리를 오래 쓰는 설정을 소개한다.	〔0.90, 0.10〕
B	영어: This setting helps the battery last longer.	〔0.85, 0.15〕
C	한국어: 축구팀의 우승 소식.	〔0.10, 0.90〕

B는 ‘이 설정은 배터리를 더 오래 쓰도록 돕는다’는 뜻입니다. 두 좌표의 차이를 살펴보는 이 단순 예에서는 A와 B의 차이가 각각 0.05로 작습니다. A와 C의 차이는 각각 0.80으로 큽니다. 따라서 언어가 다른 A · B가, 같은 한국어인 A · C보다 내용상 가까운 상황을 표현합니다. A와 B를 묶고 C를 따로 두면 ‘언어별 묶음’과 다른 결과가 됩니다.

실제 임베딩은 더 많은 숫자를 사용할 수 있으며, 각 숫자에 '배터리'나 '축구'처럼 사람이 읽을 수 있는 뜻이 정해져 있지는 않습니다. 숫자를 임의로 만들어 넣는 대신 학습된 문서 표현 모델로 계산합니다. 숫자가 크다는 이유만으로 더 좋은 문서나 높은 정답 확률을 뜻하지도 않습니다.

가까움은 선택한 모델과 비교 계산의 기준입니다. 사람이 원하는 주제의 비슷함과 다를 수 있습니다. 따라서 A · B처럼 같은 내용의 한영 문서가 가까운지, A · C처럼 같은 언어이지만 내용이 다른 문서가 구분되는지 함께 확인합니다. 실제 표현 모델과 거리 · 유사도를 계산하는 방법은 Chapter 5에서 배웁니다. 여기서는 **문서를 숫자로 표현해야 계산으로 비교할 수 있고, 그 표현이 묶음의 품질에 영향을 준다**는 관계를 이해하면 됩니다.

5. 학습과 추론은 언제 일어날까요

5.1 학습은 데이터에서 계산 기준을 얻는 과정입니다

학습에서는 데이터를 사용해 모델의 파라미터를 구하거나 조정합니다. 지도학습 신경망에서는 예측과 정답의 차이를 줄이도록 숫자를 조정합니다. 이 과목의 작은 지도학습 실습에서는 정답 문서에 등장한 단어를 정해진 방법으로 세어 점수를 얻습니다. 군집화는 정답 라벨 대신 데이터 사이의 비슷함을 활용합니다. 학습 방법에 따라 구체적인 계산은 다릅니다.

데이터와 학습 절차 → 학습된 모델이라는 흐름을 기억하세요. 지도학습 분류의 데이터에는 정답 라벨도 포함됩니다.

5.2 추론은 학습한 기준으로 새 입력을 처리하는 과정입니다

학습이 끝나면 새로운 문서를 넣어 결과를 계산합니다.

새 문서와 학습된 모델 → 예측 결과가 추론입니다.

일반적인 추론에서는 결과를 한 번 출력했다고 모델의 가중치가 자동으로 바뀌지 않습니다. 사람이 결과를 수정하더라도, 그 피드백으로 다시 학습하는 과정이 따로 있어야 모델에 반영됩니다.

5.3 평가는 목적에 맞게 결과를 확인하는 과정입니다

정답이 있는 지도학습 분류에서는 예측과 정답을 비교합니다. 시험을 볼 때 정답지를 먼저 보지 않듯, 입력만 모델에 주고 예측을 구한 다음 따로 보관한 정답과 비교합니다. 아래 표는 이 지도학습 예제의 과정입니다.

상황	무엇을 하는 중인가요?
정답 문서로 단어 점수를 구한다	학습
구한 점수로 새 문서를 분류한다	추론
예측과 따로 보관한 정답을 비교한다	평가
결과가 틀려 학습 자료를 보완하고 점수를 다시 구한다	추가 학습·재학습

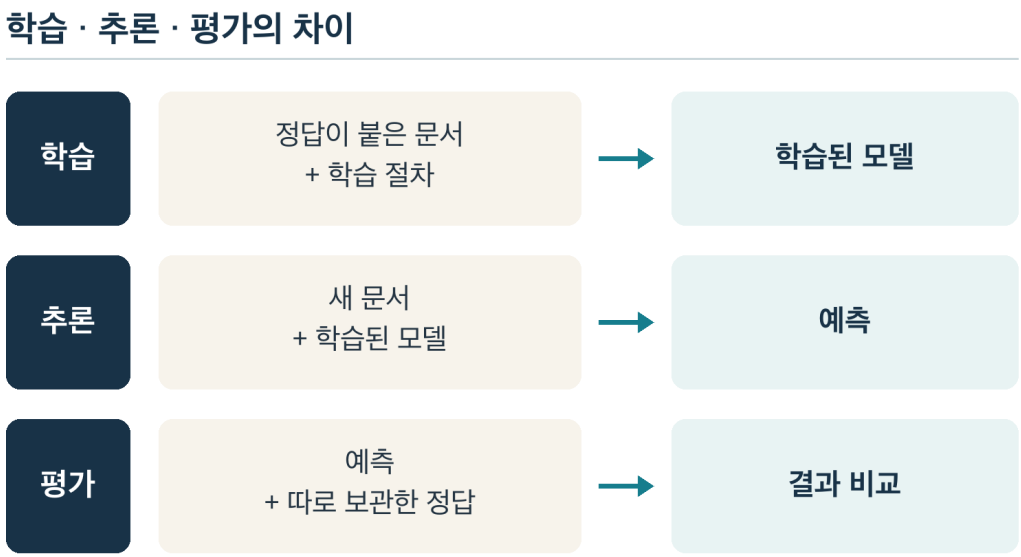


그림 3. 지도학습 분류 예제로 본 학습, 추론, 평가. 일반적인 추론에서는 학습된 숫자를 바꾸지 않습니다. 군집화와 요약은 작업 목적에 맞는 평가를 사용합니다.

학습에 쓴 문서를 잘 맞히는 것만으로 충분하지 않습니다. 처음 보는 문서에도 배운 기준을 적용해 잘 처리하는 능력을 **일반화**라고 합니다. 반대로 학습 자료에만 있는 우연한 특징까지 지나치게 맞춰 새로운 자료에서 성능이 나빠지는 현상을 **과적합**이라고 합

니다. 학습 결과가 좋아져도 새로운 자료의 결과가 함께 좋아지는지 확인해야 하는 이유입니다.

지도학습 분류에서는 자료를 역할별로 나누어 이를 확인합니다.

자료	역할
학습 자료	모델의 파라미터를 구하거나 조정할 때 사용
검증 자료	학습 중간에 결과를 살펴보고 학습 방법이나 모델을 선택할 때 사용
최종 평가 자료, 테스트 자료	선택을 마친 모델을 따로 보관한 자료로 마지막에 확인

서로 다른 원문 100개를 나누는 예

한국어와 영어로 된 문서 100개와 각 문서의 정답 라벨을 준비했다고 가정합니다. 복사본이나 같은 원문의 번역을 별도 원문으로 세지 않은 수입니다. 이 자료를 학습 60개, 검증 20개, 최종 평가 20개로 나눕니다. 60:20:20은 역할을 이해하기 위한 예시이며 정해진 표준 비율이 아닙니다. 자료의 양과 목적에 따라 조정해야 합니다.

1. 학습 60개로 단어 점수를 구합니다. 검증 · 최종 평가 문서의 정답은 이 점수 계산에 넣지 않습니다.
2. 검증 20개의 입력으로 예측하고, 그 정답과 비교합니다. 예를 들어 살펴볼 단어를 네 개로 정한 방법과 여섯 개로 정한 방법을 비교해 고릅니다. 각 방법의 점수는 학습 60개에서만 구합니다.
3. 방법과 모델을 선택하면 더 이상 바꾸지 않고, 따로 보관한 최종 평가 20개로 마지막 결과를 확인합니다.

순서는 **학습 → 검증으로 비교·선택 → 최종 평가**입니다. 최종 평가 결과를 보고 단어 목록을 계속 고치면, 가중치를 그 자료로 직접 학습하지 않았어도 그 자료에 맞는 방법을 고르게 됩니다. 그런 결과는 완전히 새로운 문서에 대한 평가라고 보기 어렵습니다. 그 결과를 계기로 다시 개선한다면, 마지막 확인에는 개발 과정에서 쓰지 않은 새 평가 자료가 필요합니다. 검증 자료에만 맞추면 같은 문제가 생길 수 있습니다.

섞이면 안 되는 것은 무엇일까요?

원문 A를 앞부분 A-1과 뒷부분 A-2로 잘랐다고 합시다. A-1은 학습에, A-2는 최종 평가에 넣으면 문장이나 내용이 겹칠 수 있습니다. 복사한 문서나 A를 번역한 문서를 반대쪽에 넣어도 처음 보는 내용인지 판단하기 어려워집니다. 이렇게 독립적으로 남겨야 할 평가 자료의 정보가 학습이나 선택 과정에 들어가 결과를 부풀리는 문제를 데이터 누수, 데이터 혼입이라고 부릅니다.

먼저 복사본을 정리하고, 같은 원문에서 나온 조각 · 번역문은 하나의 원문 묶음으로 관리합니다. 그 묶음 전체를 학습·검증·최종 평가 중 한쪽에만 넣습니다. 원문 묶음을 세 자료에 배정한 뒤, 각 자료 안에서 필요한 조각을 만듭니다. 파일명이 다르다는 이유만으로 서로 다른 자료라고 판단하지 않습니다.



그림 4. 자료를 역할별로 분리하는 예. 같은 원문의 복사본·조각·번역문은 같은 쪽에 둡니다. 60:20:20은 설명용 비율이며, 원문 수와 조각 수는 구분합니다.

무작위로 나누면 항상 충분할까요?

실제로 한영 문서를 처리할 목적이라면 세 자료에 한국어 · 영어와 주요 주제가 어떻게 들어갔는지 확인합니다. 최종 평가에 한국어 IT 문서만 있다면 영어 스포츠 문서를 잘 처리하는지는 알 수 없습니다. 대표성은 앞으로 처리할 문서의 특징을 평가 자료가 얼마나 잘 담는지를 뜻합니다. 언어와 주제뿐 아니라 길이 · 형식 등이 실제 사용 자료와 크게 다른지도 살펴봅니다. 단순히 파일을 무작위로 섞는 것만으로 대표성이 보장되지는 않습니다.

원문 20개에서 18개를 맞히면 18÷20=90%입니다. 이때 한 개의 정오답만 바뀌어도 5%포인트가 달라집니다. 따라서 작은 평가 자료에서 얻은 90%를 모든 문서의 성능이라고 단정하지 않습니다. 여러 종류의 새 자료를 충분히 모으고, 전체 결과와 언어 · 주제별 실패를 함께 확인해야 합니다. 자료를 평가용으로 더 남기면 결과를 판단하는 데 도움이 되지만 학습에 쓸 자료는 줄어듭니다. 이 균형을 생각하며 자료의 수와 분리 방법을 정합니다.

군집화에서는 미리 정답 이름이 없을 수 있습니다. 대표 문서들이 내용상 비슷한지, 언어만 같아서 묶인 것은 아닌지 등을 검토합니다. 그룹 번호가 사람의 번호와 같다는 이유로 정확하다고 판단하지 않습니다. 요약에서는 핵심 내용이 담겼는지와 원문의 사실을 바꾸지 않았는지를 확인합니다.

5.4 사전학습과 추가학습과 추론

문서 AI를 만들 때 모든 것을 처음부터 학습할 필요는 없습니다. 이미 학습된 모델에서 출발하면 기존에 배운 언어 패턴을 활용할 수 있기 때문입니다.

구분	쉬운 뜻과 예
사전학습 pretraining	많은 자료로 기본 패턴을 미리 배우는 과정. 언어모델이라면 본문의 일부나 다음 부분을 정답으로 삼아 예측하는 작업 등으로 학습
추가학습 fine-tuning	이미 학습한 모델을 내 작업의 자료로 더 조정하는 과정. 문서와 원하는 요약 예시를 사용해 요약 작업에 맞출 수 있음
추론 inference	준비된 모델로 새 문서의 결과를 계산하는 과정. 일반적인 추론에서는 모델의 가중치를 바꾸지 않음

사전학습 모델을 불러오기 → 우선 추론해 평가하기 → 필요할 때 추가학습 → 다시 평가하기로 접근합니다. 모델에 '이 문서를 요약해 줘'라는 요청을 넣는 것만으로 추가학습이 되는 것은 아닙니다. 추가학습은 가중치를 바꾸는 별도 과정입니다.

문서 요약 모델로 생각해 보기

기존 모델이 제품 안내 문서를 요약할 때 배포일을 자주 빠뜨린다고 가정합시다. 다음은 실제 성능 측정값이 아닌, 작업 순서를 설명하는 사례입니다.

단계	하는 일	모델의 가중치
원래 결과 확인	기존 모델에 문서를 넣어 핵심 누락·사실 오류를 기록	그대로 사용
필요성 판단	요청에 배포일을 포함하라고 적어도 부족한지, 원하는 요약 기준이 명확한지 확인	그대로 사용
추가학습	학습용 원문과 원하는 요약을 짝지어, 예시 요약을 예측하도록 계산하고 오차를 줄이는 방향으로 조정	학습 대상 가중치를 변경
검증과 최종 평가	검증 자료로 학습 방법을 고른 뒤, 쓰지 않은 새 문서에서 원래 모델과 결과 비교	평가 중에는 그대로 사용

예를 들어 학습용 원문이 '새 버전은 금요일에 배포된다. PDF 요약 기능이 추가된다'라면 원하는 요약 예시는 '금요일 배포되는 새 버전에 PDF 요약 기능이 추가된다'로 만들 수 있습니다. 추가학습에서는 이러한 원문 · 요약 쌍을 여러 개 사용해 원문을 입력으로, 원하는 요약을 학습 목표로 삼습니다. 실제 언어모델은 요약을 이루는 부분들을 순서대로 예측하는 계산 등을 사용합니다. 단순히 문서 파일을 저장하거나 정답 요약을 화면에 보여 주는 것만으로 학습되는 것은 아닙니다.

요청문에 '배포일을 포함해 요약해 줘'라고 적는 것은 모델에 줄 입력을 바꾸는 일입니다. 가중치를 고치는 학습과 다릅니다. 그 요청만으로 목적에 충분하다면 추가학습이 필요하지 않을 수도 있습니다. 추가학습을 하더라도 예시에만 맞추거나 원래 능력이 나빠질 수 있으므로, 실제로 개선됐는지 별도 자료로 확인합니다. 한국어 자료로만 확인한 결과를 영어에도 그대로 적용하지 않습니다.

사전학습 모델은 기존의 언어 패턴을 활용하는 출발점이지, 내 문서와 언어에서의 품질을 보장하는 완성품은 아닙니다. 여기서는 요청해서 결과를 계산하는 것과 자료로 가중치를 조정하는 것을 구분합니다. 실제 모델 사용과 추가학습 방법은 Chapter 5와 Chapter 7에서 배웁니다.

6. 분류와 두 가지 요약 방식

다음 원문을 함께 사용해 봅시다.

> ① 문서 관리 앱의 업데이트는 금요일에 배포된다. ② 이번 업데이트에는 PDF 요약 기능이 추가된다. ③ 설정 화면의 아이콘도 바뀐다.

6.1 분류

정해진 종류 중에서 문서에 맞는 종류를 고릅니다.

> 출력 예시: IT

분류 기준을 먼저 정해야 합니다. 이 문서에는 회사나 제품 가격이 언급되어도 주요 내용이 앱 기능이라면 IT로 분류할 수 있습니다.

이 분류는 정해진 종류를 맞히는 비교 예제입니다. 최종 목표의 군집화는 문서 모음에서 비슷한 내용을 찾아 N개 그룹으로 묶는 작업입니다.

6.2 추출 요약

원문에서 중요한 문장을 선택합니다.

> 출력 예시: 문서 관리 앱의 업데이트는 금요일에 배포된다. 이번 업데이트에는 PDF 요약 기능이 추가된다.

문장을 그대로 가져와도 중요한 문장을 빠뜨리거나, 앞뒤 문맥을 빼서 의미가 달라질 수 있습니다. 문장을 복사했다는 사실만으로 좋은 요약이 되지는 않습니다.

6.3 생성형 요약

원문의 내용을 바탕으로 새로운 문장을 작성합니다.

출력 형식 예시: 금요일 업데이트로 문서 관리 앱에 PDF 요약 기능이 추가된다.

읽기 쉬운 문장을 만들 수 있지만, 원문에 없는 정보를 넣거나 사실을 바꿀 수도 있습니다. 예를 들어 '토요일에 자동 번역 기능이 추가된다'는 요약은 날짜와 기능이 모두 잘못됐습니다. 이러한 오류를 환각이라고 부릅니다.

위 출력은 방식의 차이를 보여 주기 위해 직접 작성한 예시입니다. 실제 모델의 실행 결과나 성능 측정값은 아닙니다.

영어도 같은 원리로 요약합니다. 예를 들어 'The app update arrives on Friday. It adds PDF summaries.'를 'The Friday update adds PDF summaries.'로 정리할 수 있습니다. 이 교재에서는 한국어 원문은 한국어로, 영어 원문은 영어로 요약하는 예제부터 사용합니다. 요약과 다른 언어로 번역하는 작업은 구분합니다.

6.4 모델을 고르는 방향

기초 비교용 분류에는 작은 전용 모델을 사용할 수 있습니다. 군집화에서는 문서를 숫자로 표현하는 모델과 그 숫자로 비슷한 문서를 묶는 방법을 배웁니다. 추출 요약은 간단한 문장 점수 계산으로 시작할 수 있고, 생성형 요약은 문장을 생성할 수 있는 모델을 사용합니다. 한영 요약과 군집화는 각각의 목적에 맞게 결과를 확인합니다.

같은 원문에서 세 가지 다른 결과

원문

앱 업데이트는 금요일에 배포된다.
PDF 요약 기능이 추가된다. 설정 아이콘도 바뀐다.

분류	추출 요약	생성형 요약
정해진 종류 선택	원문 문장 선택	새 문장 작성
IT	앱 업데이트는 금요일에 배포된다. PDF 요약 기능이 추가된다.	금요일 앱 업데이트에 PDF 요약 기능이 추가된다.

표현이 자연스러워도 원문의 사실과 맞는지 확인합니다.

그림 5. 같은 원문에서 나오는 세 가지 결과. 생성형 요약은 표현뿐 아니라 사실 일치도 확인합니다.

7. 실습 1 손으로 학습하고 추론하기

목표: 지도학습 비교 예제로, 학습에서 숫자를 얻고 추론에서는 그 숫자를 사용한다는 차이를 직접 확인합니다. 이 점수표는 최종 목표인 비지도 군집 모델이 아닙니다.

설명을 단순하게 만들기 위해 이 실습만 IT와 스포츠 두 종류를 사용합니다. 다음 실습에서 IT · 경제 · 스포츠 세 종류로 확장합니다.

7.1 사람이 먼저 정할 것

- 살펴볼 문자열은 '스마트폰', '배터리', '선수', '경기' 네 가지입니다.
- 점수는 모두 0에서 시작합니다.
- IT 문서에 들어 있는 문자열의 점수에는 1을 더합니다.
- 스포츠 문서에 들어 있는 문자열의 점수에서는 1을 뺍니다.
- 각 문자열은 문서 하나에서 여러 번 나와도 한 번만 반영합니다.

이번에는 문자열이 들어 있는지만 확인하므로 '스마트폰으로'에도 '스마트폰'이 있다고 봅니다. 단어 분리와 문맥 처리는 뒤에서 배웁니다.

7.2 학습 자료

번호	문서	정답
A	스마트폰 배터리 개선 소식	IT
B	스마트폰 신제품 발표	IT
C	선수 경기 인터뷰	스포츠
D	경기 결과 발표	스포츠

먼저 해설을 보지 말고 점수를 채워 보세요.

문자열	처음	A 반영 후	B 반영 후	C 반영 후	D 반영 후
스마트폰	0				
배터리	0				
선수	0				
경기	0				

7.3 처음 보는 입력으로 추론하기

점수표가 완성되면 고정합니다. 아래 문서에 들어 있는 문자열의 점수를 더하세요.

- 합이 양수이면 IT로 예측합니다.
- 합이 음수이면 스포츠로 예측합니다.
- 합이 0이면 이 실습의 규칙에 따라 판단을 보류합니다.

새 입력	점수 합	예측
배터리 수명 안내		
선수 경기 기록		
스마트폰으로 경기 촬영		
김치찌개 만드는 방법		
경기도 버스 노선 안내		

이 점수는 계산에 사용하는 값이며, 정답일 확률이나 신뢰도를 뜻하지 않습니다.

7.4 생각할 질문

1. 문자열의 종류를 고른 것과 점수를 얻은 것은 어떻게 다른가요?
2. 새 문서를 분류할 때 점수표를 바꿨나요?
3. 점수 합이 0인 두 문서는 같은 이유로 0이 되었나요?
4. ‘경기도 버스 노선 안내’를 잘못 판단했다면 무엇이 부족했나요?

이 실습은 학습 원리를 보여 주는 매우 작은 분류 모형입니다. 문자열 목록과 계산 절차는 사람이 설계했고, 점수는 정답 데이터에서 구했습니다. 손으로 수행한 계산을 프로그램으로 반복하면 컴퓨터가 같은 절차로 점수를 얻을 수 있습니다. 모델이 스스로 무엇이든 발견하는 것은 아닙니다.

판단 보류도 이 실습에서 정한 규칙입니다. 실제 모델에서도 언제 보류할지 기준을 정하고 검증해야 하며, AI가 모르는 입력을 자동으로 알아낸다고 가정하지 않습니다.

8. 실습 2 문서 30개에 라벨 붙이기

목표: 지도학습 분류에서는 사람이 일관된 정답 기준을 만들어야 한다는 점을 경험합니다. 이 비교 실습의 라벨을 최종 비지도 군집화의 학습 정답으로 사용하지는 않습니다.

8.1 이번 실습의 분류 기준

라벨	기준
IT	기술·제품·앱의 기능이나 작동 방법이 주요 내용
경제	매출·실적·가격·금리·무역·고용 같은 경제 활동이 주요 내용
스포츠	경기 결과·기록·선수의 훈련·전술이 주요 내용

이 문서가 주로 무엇을 설명하는지를 기준으로 하나를 고릅니다. 유명한 회사나 특정 단어가 나온다는 이유만으로 결정하지 않습니다.

하나를 고르기 어렵다면 '보류'라고 적고 이유를 남기세요. 보류는 이 손실습의 기록 상태입니다. 이 예제의 세 종류 분류기가 자동으로 출력하는 네 번째 라벨이라고 가정하지 않습니다.

8.2 라벨링 표

각 행을 짧은 문서 한 개로 보고 '내 판단'과 '이유'를 적습니다. 아래 문서는 모두 이 교재에서 만든 가상의 연습 문장입니다.

번호	문서	내 판단	이유
1	새 스마트폰의 카메라 기능과 촬영 설정을 소개한다.		
2	기업의 올해 영업이익이 지난해보다 늘었다.		
3	축구팀이 결승전에서 승리해 우승했다.		
4	앱 업데이트로 문서를 폴더별로 정리하는 기능이 추가됐다.		
5	환율 변동이 수출 기업의 실적에 미친 영향을 분석한다.		
6	수영 선수가 자유형 경기에서 개인 최고 기록을 세웠다.		
7	운영체제 업데이트가 보안 취약점을 수정했다.		
8	식료품 물가 상승으로 가계의 생활비 부담이 커졌다.		
9	야구팀의 선발 투수가 다음 경기를 준비하며 훈련했다.		
10	프로그램에서 PDF의 텍스트를 추출하는 방법을 설명한다.		
11	유통 회사가 분기 매출과 영업이익을 발표했다.		
12	마라톤 선수가 종전 기록을 단축하며 결승선을 통과했다.		
13	배터리 충전 속도를 높이는 새 기술의 원리를 설명한다.		

번호	문서	내 판단	이유
14	중앙은행의 금리 결정이 금융시장에 미친 영향을 다룬다.		
15	농구 선수가 한 경기에서 최다 득점을 올렸다.		
16	두 CPU의 계산 성능과 소비 전력을 비교한다.		
17	고용 통계에 나타난 취업자 수와 실업률 변화를 분석한다.		
18	배드민턴 선수의 경기 운영과 전술을 설명한다.		
19	스마트폰 회사의 매출과 이익이 증가한 이유를 분석한다.		
20	축구 경기 기록을 관리하는 앱의 새 기능을 소개한다.		
21	프로야구단의 입장권 매출과 운영 비용을 분석한다.		
22	스포츠 촬영용 카메라의 자동 초점 기능을 설명한다.		
23	반도체 수출 금액이 전체 수출에서 차지하는 비중을 분석한다.		
24	스마트폰으로 촬영한 영상을 활용해 축구 선수의 전술을 분석한다.		
25	전반부는 새 앱의 기능을, 후반부는 회사의 실적을 같은 비중으로 다룬다.		
26	한 문서에 수영 경기 결과와 스마트폰 신제품 소개가 함께 들어 있다.		

번호	문서	내 판단	이유
27	제목은 선수의 광고 계약 발표이며, 본문은 제공되지 않았다.		
28	김치찌개 재료와 조리 순서를 설명한다.		
29	여행지의 숙소와 관광 코스를 소개한다.		
30	내용이 없는 빈 문서다.		

8.3 기록할 것

1. 어려웠던 문서를 최소 3개 고르고 이유를 적습니다.
2. ‘주제가 섞임’, ‘기존 분류에 해당하지 않음’, ‘입력 부족’을 구분합니다.
3. 나와 다른 사람이 같은 자료를 분류해도 비슷한 결과가 나오도록 기준을 한 문장 보완합니다.

빈 문서는 입력 검사로 걸러낼 수 있습니다. 반면 주제가 범위 밖인지 판단하는 일은 별도의 설계와 평가가 필요할 수 있습니다. 모든 문서를 세 종류 중 하나로 억지로 넣으면 그럴듯한 오답이 나올 수 있습니다.

8.4 라벨 없이 한국어·영어 문서 묶어 보기

이번에는 정답 주제를 붙이지 않고 비슷한 문서를 모읍니다. 아래 문서의 A~H는 문서를 구별하는 표시이며 정답 라벨이 아닙니다.

문서	내용
A	스마트폰 배터리를 오래 사용하는 설정을 소개한다.
B	The phone has a battery-saving setting.
C	앱에서 문서를 폴더로 정리하는 방법을 설명한다.
D	The app sorts documents into folders.
E	축구팀이 결승전에서 우승했다.
F	The football team won the final.
G	농구 선수가 경기에서 30점을 넣었다.
H	The basketball player scored 30 points.

영어 읽기가 어렵다면 다음 뜻을 참고하세요. B는 '휴대폰에 배터리 절약 설정이 있다', D는 '앱이 문서를 폴더로 정리한다', F는 '축구팀이 결승전에서 이겼다', H는 '농구 선수가 30점을 넣었다'입니다. 이것은 실습을 돕는 뜻풀이이며, 모델이 번역한 결과는 아닙니다.

1. 먼저 그룹 이름을 정하지 말고, 문서 내용의 비슷함을 기준으로 N=2인 두 묶음을 만듭니다. 모든 문서를 한 묶음에 한 번씩 넣습니다.
2. 묶은 다음 각 그룹에서 대표 문서 하나와 핵심어를 고르고, 설명용 이름을 붙입니다.
3. 같은 문서를 다시 살펴보고 N=3인 세 묶음을 만듭니다. 처음의 두 묶음을 반드시 유지할 필요는 없습니다.
4. N을 바꾸니 무엇이 더 자세히 나뉘었는지, 같은 내용의 한국어 · 영어가 함께 묶였는지 적습니다.

설정	문서들을 묶은 결과	대표 문서·핵심어·그룹 이름
N=2		
N=3		

이것은 군집화의 목적을 이해하는 손실습입니다. 사람이 내용을 읽고 묶은 것이므로 실제 군집 모델을 학습하거나 정확도를 평가한 실험은 아닙니다. 11.3절의 묶음은 가능한 예시일 뿐 유일한 정답은 아닙니다. 실제 모델이 언어보다 내용을 잘 반영하는지는 이후 별도로 검증합니다.

9. 실습 3 분류와 요약을 구분하기

다음 원문에서 요약에 포함할 핵심 정보를 ‘배포일’과 ‘제공 기능’으로 정했다고 가정합니다.

> 문서 앱의 새 버전은 금요일에 배포된다. 이번 버전은 PDF 요약 기능을 제공한다. 설정 화면의 아이콘도 바뀐다.

직접 다음 세 가지를 작성하세요.

1. IT · 경제 · 스포츠 중 분류 하나를 고릅니다.
2. 원문 문장 두 개를 선택해 추출 요약을 작성합니다.
3. 원문에 있는 사실만 사용해 한 문장으로 다시 요약합니다.

그다음 아래 요약이 적절한지 판단해 보세요.

> 문서 앱이 토요일에 업데이트되며 자동 번역 기능을 제공한다.

무엇이 잘못됐는지 원문과 대조해서 설명합니다. 글이 자연스러운지와 원문에 맞는지는 서로 다른 평가 항목입니다.

10. 확인 문제

먼저 해설을 보지 말고 한두 문장으로 답해 보세요.

1. AI와 머신러닝과 딥러닝은 서로 어떤 관계인가요?
2. ‘IT 문서에 스마트폰이 있으면 그 점수에 1을 더한다’라는 학습 절차와, 그 절차로 얻은 최종 점수표는 각각 어떤 역할인가요?
3. 새 문서를 분류하는 동안 점수표를 고정해서 사용했다면 학습인가요, 추론인가요?
4. 사람이 분류 결과를 수정하면 모델이 자동으로 학습하나요?
5. ‘스마트폰 회사의 매출 분석’이 경제로 분류될 수 있는 이유는 무엇인가요?
6. 추출 요약은 원문 문장을 가져오므로 항상 올바른 요약인가요?
7. 사전학습 모델에 ‘문서를 요약해 줘’라고 요청하면 추가학습이 되나요?
8. 검증 자료로 모델을 고른 뒤 최종 평가 자료를 따로 쓰는 이유는 무엇인가요?
9. 분류할 수 있는 종류가 세 개뿐인 모델에 요리 문서를 넣으면 반드시 ‘모름’을 출력하나요?
10. 학습에 쓴 문서에서 잘 맞혔다는 결과만으로 모델 품질을 판단해도 될까요?
11. 비지도 군집화도 문서마다 IT · 경제 · 스포츠 정답을 먼저 붙여야 하나요?
12. N=3으로 묶은 결과에서 ‘그룹 0’은 항상 같은 주제를 뜻하나요? N은 주제 이름인가요?
13. 한국어와 영어 문서가 서로 다른 그룹으로 깔끔하게 나뉘면, 내용별 군집화 목표를 달성했다고 볼 수 있나요?
14. 같은 원문을 잘라 만든 A-1을 학습에, A-2와 그 원문의 영어 번역을 최종 평가에 넣었습니다. 파일명이 모두 다르면 괜찮을까요? 어떻게 나누어야 할까요?

11. 실습과 확인 문제 해설

11.1 실습 1 점수표

문자열	처음	A 반영 후	B 반영 후	C 반영 후	D 반영 후
스마트폰	0	1	2	2	2
배터리	0	1	1	1	1
선수	0	0	0	-1	-1
경기	0	0	0	-1	-2

새 입력	계산	예측
배터리 수명 안내	1	IT
선수 경기 기록	-1 + -2 = -3	스포츠
스마트폰으로 경기 촬영	2 + -2 = 0	판단 보류
김치찌개 만드는 방법	해당 문자열 없음, 합계 0	판단 보류
경기도 버스 노선 안내	'경기'가 포함되어 -2	스포츠로 오판

스마트폰과 경기가 함께 있는 문서는 점수가 서로 상쇄됐습니다. 요리 문서는 아는 문자열이 없어 0이 됐습니다. 같은 점수여도 이유가 다릅니다.

'경기도'의 일부를 경기로 찾는 것은 문자열 포함만 검사하는 방식의 한계입니다. 단어 분리와 문맥이 중요해지는 이유를 보여 줍니다. 새로운 표현을 잘 처리할 수 있는지는 별도로 평가해야 합니다.

사람이 고른 것은 문자열 목록과 점수를 얻는 절차입니다. 실제 점수는 학습 자료에서 계산했습니다. 추론할 때는 점수표를 바꾸지 않았습니다.

11.2 실습 2 라벨링 예시

번호	예시 판단	이유
1·4·7·10·13·16	IT	기능·작동 방법·기술의 성능이 주요 내용
2·5·8·11·14·17	경제	실적·물가·금리·고용 등 경제 활동이 주요 내용
3·6·9·12·15·18	스포츠	경기 결과·기록·훈련·전술이 주요 내용
19	경제	스마트폰 회사이지만 설명의 중심은 매출과 이익
20	IT	축구가 등장하지만 설명의 중심은 앱 기능
21	경제	야구단의 경기 결과보다 매출과 비용을 다룸
22	IT	스포츠가 등장하지만 카메라 기능을 설명
23	경제	반도체 기술보다 수출 금액과 비중을 분석
24	스포츠	스마트폰은 도구이고 주요 내용은 선수의 전술
25·26	보류	서로 다른 주제가 섞여 하나를 고를 기준이 부족함
27	보류	제목만으로는 경기·선수 활동 중심인지 계약 금액 분석인지 부족함
28·29	보류	현재 세 종류의 분류 범위에 맞지 않음
30	입력 오류	분석할 내용이 없음

19~27번은 분류 기준의 영향을 살펴보기 위한 예제입니다. 다른 판단을 했다면 이유를 비교하고 기준을 보완하세요. 실제 서비스에서 복수 라벨을 허용할 수도 있지만, 이 실습에서는 하나를 고르는 기준으로 연습합니다.

11.3 라벨 없이 묶기 실습 예시

아래 이름은 문서들을 묶은 다음 내용을 설명하려고 붙인 것입니다. 그룹 번호나 이름을 먼저 정답으로 준 것이 아닙니다.

설정	묶은 문서	나중에 붙인 설명용 이름
N=2	A·B·C·D	휴대폰·앱 기능
N=2	E·F·G·H	스포츠 경기
N=3	A·B	배터리 설정
N=3	C·D	문서 정리 앱
N=3	E·F·G·H	스포츠 경기

예를 들어 N=3의 A · B 묶음에서는 A를 대표 문서로, '배터리 · 절약 · 설정'을 핵심어로 고를 수 있습니다. 한국어 · 영어의 문장이 완전히 같지 않아도 비슷한 주제를 다룬다는 점을 살펴봅니다.

N=2에서는 휴대폰과 앱의 기능을 넓게 묶었고, 이 N=3 예시에서는 둘을 더 세부적으로 나눴습니다. 다른 가능한 N=3 결과는 A · B · C · D, E · F, G · H로 묶어 '기기 · 앱 기능 / 축구 / 농구'로 설명하는 것입니다. N만으로 그룹의 주제나 세부 수준이 하나로 결정되지는 않습니다. 실제 군집 계산에서도 N을 바꾸면 이전 그룹이 그대로 유지된다는 보장은 없습니다.

문서를 언어별로만 나눴다면 서로 다른 내용이 한 그룹에 섞일 수 있습니다. 이 과정의 목표는 같은 내용의 한영 문서도 함께 살펴볼 수 있는 군집화입니다. 다만 이 손실습의 결과가 특정 모델이 그렇게 동작한다는 증거는 아닙니다. 모델 평가는 Chapter 6에서 별도로 배웁니다.

11.4 실습 3 요약 예시

- 분류: IT
- 추출 요약: '문서 앱의 새 버전은 금요일에 배포된다. 이번 버전은 PDF 요약 기능을 제공한다.'
- 한 문장 요약: 금요일 배포되는 문서 앱의 새 버전은 PDF 요약 기능을 제공한다.
- 잘못된 요약의 문제: 금요일을 토요일로 바꾸었고 PDF 요약을 자동 번역으로 바꾸었습니다.

11.5 확인 문제 해설

1. AI가 가장 넓은 분야이며, 머신러닝은 AI의 한 접근법이고 딥러닝은 머신러닝의 한 종류입니다.
2. 점수를 얻는 절차는 사람이 설계한 학습 방법이고, 최종 점수표는 데이터에서 구한 파라미터입니다. 점수표와 예측 계산을 함께 사용해 작은 모델을 구성합니다.
3. 이미 얻은 파라미터로 결과를 계산하므로 추론입니다.
4. 자동으로 학습하지 않습니다. 피드백을 모아 재학습하거나 모델을 갱신하는 과정이 별도로 있어야 합니다.
5. 회사의 업종보다 문서의 주요 내용을 기준으로 정했기 때문입니다. 이 예에서는 매출과 이익이 중심입니다.
6. 아닙니다. 핵심 누락이나 문맥 손실이 생길 수 있습니다.
7. 아닙니다. 준비된 모델로 결과를 계산하는 것은 추론입니다. 추가학습은 자료를 사용해 가중치를 조정하는 별도 과정입니다.
8. 검증 자료로 단어 목록이나 모델을 골랐다면 그 선택에 이미 영향을 준 자료입니다. 별도로 보관한 최종 평가 자료로 선택을 마친 모델을 확인해야 합니다. 최종 평가에서 틀린 문서를 보고 목록을 바꾼 뒤 같은 자료로 다시 평가하면, 처음 보는 문서에서의 결과라는 근거가 약해집니다.
9. 아닙니다. 설계에 따라 기존 세 종류 중 하나를 출력할 수 있습니다. 보류 · 범위 밖 처리는 별도로 마련해야 합니다.
10. 충분하지 않습니다. 처음 보는 문서에서도 결과를 확인해야 합니다.
11. 아닙니다. 이 목표의 비지도 군집화는 문서의 정답 주제 라벨 없이 비슷한 문서들을 묶습니다. 결과를 검토하거나 평가할 때 사람이 참고 정보를 붙이는 일과 학습에 정답을 주는 일은 구분합니다.
12. 아닙니다. N은 만들 그룹 수입니다. 그룹 0은 구별용 번호이며 의미가 고정되지 않습니다. 사람이 대표 문서와 핵심어를 검토해 설명용 이름을 붙입니다.
13. 그렇다고 단정할 수 없습니다. 문서의 내용에 따라 묶였는지 확인해야 합니다. 같은 내용의 한영 문서가 갈라지고, 다른 내용의 같은 언어 문서만 모였다면 목표에 맞지 않을 수 있습니다.
14. 파일명이 달라도 내용이 겹치면 평가가 부풀 수 있습니다. 같은 원문의 복사본 · 조각 · 번역문을 묶어 학습 · 검증 · 최종 평가 중 한쪽에만 배정합니다.

12. 선택 실습 Python으로 같은 점수표 만들기

손 실습을 이해했다면 다음 코드를 Python 3에서 실행해 보세요. 지도학습 비교 예제인 실습 1과 같은 점수표를 만드는 코드이며, 비지도 군집 코드가 아닙니다. 기본 라이브러리만 사용합니다. 문자열 목록과 학습 절차는 코드에 정하고, 점수는 학습 자료로부터 구합니다.

Python 실습

```
words = ["스마트폰", "배터리", "선수", "경기"]
training_docs = [
    ("스마트폰 배터리 개선 소식", "IT"),
    ("스마트폰 신제품 발표", "IT"),
    ("선수 경기 인터뷰", "스포츠"),
    ("경기 결과 발표", "스포츠"),
]

# 학습: 정답 자료로 점수를 구합니다.
scores = {word: 0 for word in words}
for text, label in training_docs:
    change = 1 if label == "IT" else -1
    for word in words:
        if word in text:
            scores[word] += change

def predict(text):
    # 추론: 학습한 점수를 읽기만 합니다.
    total = sum(scores[word] for word in words if word in text)
    if total > 0:
        return "IT", total
    if total < 0:
        return "스포츠", total
    return "판단 보류", total

new_docs = [
    "배터리 수명 안내",
    "선수 경기 기록",
    "스마트폰으로 경기 촬영",
    "김치찌개 만드는 방법",
    "경기도 버스 노선 안내",
]

print("학습한 점수:", scores)
for text in new_docs:
    label, total = predict(text)
    print(f"{text} -> {label} (점수 {total})")
```

예상 출력:

예상 출력

```
학습한 점수: {'스마트폰': 2, '배터리': 1, '선수': -1, '경기': -2}
배터리 수명 안내 -> IT (점수 1)
선수 경기 기록 -> 스포츠 (점수 -3)
스마트폰으로 경기 촬영 -> 판단 보류 (점수 0)
김치찌개 만드는 방법 -> 판단 보류 (점수 0)
경기도 버스 노선 안내 -> 스포츠 (점수 -2)
```

바꿔 보기

1. new_docs에 문서를 추가합니다. 예측 결과를 보고 점수표가 자동으로 바뀌는지 확인하세요.
2. 학습 자료에 ("배터리 스마트폰 기능", "IT")를 추가하고 프로그램을 처음부터 다시 실행합니다.
3. 두 번째 실행에서는 스마트폰 3, 배터리 2가 됩니다. '스마트폰으로 경기 촬영'의 합은 1이 되어 IT가 됩니다. 정답 자료가 예측 기준에 영향을 준다는 뜻이며, 품질이 좋아졌다는 증거는 아닙니다.
4. 학습 자료의 스포츠 문서 하나를 IT라고 잘못 표시하면 어떻게 될지 예측하고 실행합니다. 실제로 잘못된 학습이므로 변경한 라벨은 실습 후 되돌립니다.

이 점수는 예측 확률이나 신뢰도가 아닙니다. 점수가 크다는 이유만으로 실제로 더 정확하다고 결론 내리지 않습니다. Python · 문서 데이터 처리는 Chapter 2에서, 머신러닝 · 군집화 기초는 Chapter 3에서 배웁니다.

13. 과목 1 완료 확인

- [ ] 모델 · 파라미터 · 학습 · 추론을 예로 들어 설명할 수 있다.
- [ ] 일반화와 과적합을 구분하고 예를 들 수 있다.
- [ ] 학습 · 검증 · 최종 평가 자료의 역할과 분리 이유를 설명할 수 있다.
- [ ] 같은 원문의 복사본 · 조각 · 번역문이 서로 다른 자료에 섞이면 왜 문제가 되는지 설명할 수 있다.
- [ ] 평가 자료의 언어 · 주제 대표성과 자료가 적을 때의 불확실성을 설명할 수 있다.
- [ ] 사전학습 모델로 추론하는 것과 추가학습으로 가중치를 바꾸는 것을 구분할 수 있다.
- [ ] 손으로 구한 점수표와 코드의 결과를 비교할 수 있다. 코드는 선택 실습이다.
- [ ] 지도학습 비교용 라벨링과 최종 목표의 비지도 군집화를 구분할 수 있다.
- [ ] 라벨 없이 한영 문서를 N=2와 N=3으로 묶고 차이를 설명했다.
- [ ] N은 그룹 수이며, 그룹 번호는 고정된 주제 이름이 아님을 설명할 수 있다.
- [ ] 분류 · 추출 요약 · 생성형 요약의 출력 차이를 설명할 수 있다.
- [ ] 한영 요약의 사실 일치와 내용별 군집화에서 확인할 점을 말할 수 있다.
- [ ] 문서 입력 · 숫자 표현 · 모델 계산 · 출력의 흐름을 설명할 수 있다.
- [ ] 설명용 좌표와 실제 모델의 임베딩을 구분하고, 같은 언어보다 같은 내용이 가깝게 표현되는 예를 들 수 있다.

이해가 막히면 모든 용어를 다시 외우기보다 실습 1의 점수표로 돌아가 '지금 숫자를 만드는 중인가, 이미 만든 숫자를 쓰는 중인가'를 확인하세요.

다음 Chapter 2에서는 Python · NumPy의 기본 계산을 익히고, 실제 텍스트 파일을 읽어 한국어 · 영어 문서 데이터를 준비합니다. 이번에 배운 입력과 숫자 표현을 코드로 다뤄 보는 단계입니다. TF-IDF나 역전파를 미리 이해해야 이번 과목을 마칠 수 있는 것은 아닙니다.

핵심 용어를 연결해서 복습하기

용어	이 과목에서 기억할 뜻
데이터·라벨	처리할 자료·지도학습에서 예측할 정답
특성·벡터	계산에 사용하는 입력 정보·순서가 있는 숫자 목록
문서 임베딩	문서 내용을 비교 계산에 쓸 수 있도록 표현한 숫자 목록
모델·파라미터	입력에서 출력을 구하는 계산 구조와 숫자·학습으로 구하거나 조정하는 숫자
학습·추론·평가	숫자를 구하거나 조정하기·준비된 모델로 결과 계산하기·목적에 맞게 결과 확인하기
일반화·과적합	새 자료에도 잘 적용하는 능력·학습 자료에 지나치게 맞춰 새 자료에서 나빠지는 현상
검증·최종 평가	방법이나 모델을 고를 때 확인·선택 후 별도 자료로 마지막 확인
데이터 누수	독립적으로 남겨야 할 평가 자료의 정보가 학습이나 선택에 들어가 결과를 부풀리는 문제
사전학습·추가학습	기본 패턴 배우기·기존 모델을 내 자료로 조정하기
분류·군집화	정해진 종류 예측·선택한 유사성 기준으로 비슷한 자료 모으기
추출 요약·생성형 요약	원문 문장 선택·원문을 바탕으로 새 문장 작성

용어 하나씩 외운 뒤 끝내기보다, '문서의 특성을 숫자로 표현하고 학습된 파라미터로 추론한 뒤 새로운 자료에서 평가한다'처럼 연결해서 설명해 보세요. 군집화라면 정답 이름을 맞히는 대신 비슷한 문서들이 유용하게 묶였는지 확인하고, 요약이라면 핵심 내용과 사실 일치를 확인한다는 차이도 덧붙입니다.