텍스트 분류·요약을 위한 온디바이스 AI 학습 계획

Android 개발 경험이 있는 AI 비전공자를 위한 입문 → 중급 기본 과정과 고급 예정 과정

학습 계획 PDF · 개정: 2026년 10월 20일 · 학습 전: 교재 PDF 미등록

최종 목표와 학습 범위

학습의 중심: 이 계획은 한국어 · 영어 텍스트를 내용에 따라 분류하고 핵심 내용을 요약하는 온디바이스 AI 모델링에 중점을 둔다. 모델링은 목적에 맞는 모델을 선택하거나 추가학습하고, 문서 입력부터 결과 확인까지의 처리 방법을 설계하는 과정이다. Android 기기에서 실행할 수 있도록 모델의 크기 · 속도 · 메모리 사용량과 분류 · 요약 품질을 함께 확인한다.

목표 1 · 문서 요약 모델 설계: 한국어 · 영어 문서의 핵심 내용을 원문 언어로 요약하는 모델과 처리 흐름을 설계한다.

목표 2 · 텍스트 분류를 위한 비지도 군집화 모델 설계: 문서 내용을 보고 N개 카테고리로 묶는 모델을 설계한다. 정답 카테고리 라벨 없이 유사한 문서를 묶는 군집화를 사용한다.

N은 설정하는 그룹 수이며, 원하는 주제가 자동으로 발견된다고 가정하지 않는다. 대표 문서 · 핵심어를 사람이 검토해 그룹의 의미와 이름을 정한다. 처음에는 한 문서를 하나의 군집에 배정하고 여러 주제가 섞인 문서는 실패 사례로 분석한다.

대상과 환경: Python과 AI의 기초부터 시작한다. 입력은 한국어 · 영어 TXT와 텍스트를 추출할 수 있는 PDF다. PC · Mac 또는 Colab에서 학습 · 비교한 뒤 Kotlin 앱의 CPU에서 검증한다. Colab은 브라우저로 접속해 클라우드 컴퓨터에서 Python을 실행하는 환경이다. 사진 속 글자를 읽는 OCR은 후속 범위다.

기본 과정 도달 수준: Chapter 1~8은 기존 모델 · 알고리즘을 이해하고 조합 · 비교 · 평가 · 배포하는 활용 · 설계 중급을 목표로 한다. 요약 모델 추가학습은 선택 심화이며, 작은 학습 실험과 원본 대비 평가까지 수행한다. 새 대규모 모델을 방대한 자료로 처음부터 학습시키는 과정은 포함하지 않는다.

고급 과정 · 학습 예정: Chapter 9~14는 기본 과정 이후 모델의 학습 방법 · 문서 표현 · 실행 비용을 개선하는 과정이다. 현재는 학습할 범위와 진입 · 완료 기준을 계획하며, 교재는 추후 작성한다. 세부 내용은 문서 뒤의 고급 과정에서 확인한다.

학습 방법과 POC 진입 조건

각 Chapter는 쉬운 이론 → 작은 예제 → 단원 실습 → 이해·평가 확인 순서로 진행한다. 기간보다 완료 기준으로 다음 단계에 진입한다. 작은 예제에서는 한 개념을, 단원 실습에서는 그 과목의 기능을 익힌다.

설명 원칙: 전문 용어는 쉬운 뜻과 함께 익힌다. 중요한 정의 · 작동 원리 · 성립 조건 · 한계를 생략하지 않으며, 예제를 실행하는 방법과 왜 그런 결과가 나오는지를 함께 배운다. 아래의 이론 범위는 학습할 항목이며, 세부 계산은 해당 Chapter에서 순서대로 설명한다.

POC는 여러 개념을 결합해 실제 문서에서 설계의 가능성과 한계를 검증하는 시제품이다. 예제 실행 성공만으로 POC를 완료하지 않는다. 필요한 이론 · 단원 실습 · 평가 학습을 마친 뒤 다음 조건을 확인한다.

- 입력 · 출력, 알고리즘의 역할, 왜 해당 방법을 사용하는지 설명할 수 있다.
- 예제의 문서 · 설정을 직접 바꾸고 결과를 재현하며 차이를 설명할 수 있다.

- 좋은 결과와 실패 사례를 구분하고, 비교할 자료와 평가 기준을 정할 수 있다.

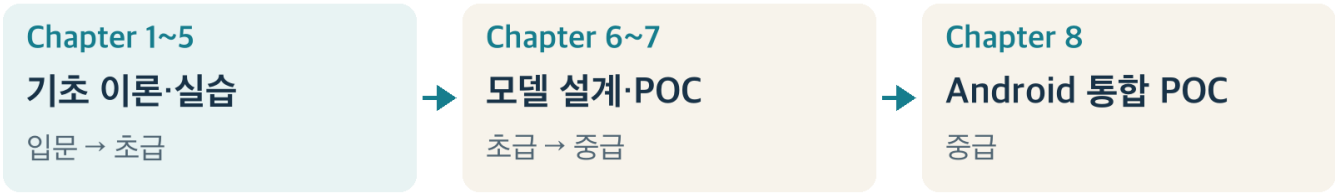


그림 1. 기본 과정의 순서. 기초 학습 → 모델별 설계·실습과 POC → Android 통합 POC를 마친 뒤 고급 과정으로 이어간다.

Chapter 1. AI와 머신러닝 기본 개념

교재 PDF: AI와_머신러닝_기본_개념.pdf

배우는 목적: ‘AI가 학습한다’ 는 말이 실제로 무엇을 뜻하는지 문서 예제로 이해한다. 자료로 모델을 학습시키는 일, 학습된 모델로 새 문서를 처리하는 일, 결과가 맞는지 확인하는 일을 구분하는 것이 이 Chapter의 핵심이다.

무엇을 배우나요? 다음 일곱 가지 질문을 순서대로 살펴본다.

1. AI·머신러닝·딥러닝은 어떻게 다른가? AI는 컴퓨터의 판단 · 인식 · 언어 처리 등을 다루는 넓은 분야다. 머신러닝은 그 안에서 데이터를 통해 패턴을 배우는 방법이다. 딥러닝은 여러 계산 층을 연결한 신경망을 학습하는 머신러닝 방식이다.
2. 모델은 무엇으로 문서를 판단하는가? ‘배터리’ 가 있는 문서를 IT로 분류하는 작은 예제를 사용한다. 문서는 데이터이고, 특정 단어가 있는지는 판단에 쓰는 단서인 특성이다. 단어별 점수를 더해 결과를 내는 계산과 점수표가 모델을 이룬다. 자료에서 구한 단어 점수처럼 학습으로 정하는 내부 숫자를 파라미터라고 부른다.
3. 학습시키는 것과 사용하는 것은 어떻게 다른가? 예제 문서에서 단어 점수를 구하는 과정이 학습이다. 그 점수로 새 문서를 분류하는 과정이 추론이다. 분류 결과를 따로 보관한 정답과 비교하는 과정이 평가다. 일반적인 추론에서는 새 문서 하나를 처리했다고 점수가 자동으로 바뀌지 않는다.
4. 정답을 알려 주고 배우는 방법과 정답 없이 묶는 방법은 어떻게 다른가? 문서에 IT · 스포츠 같은 정답 종류인 라벨을 붙여 학습하는 것이 지도학습이다. 정답 라벨 없이 문서 사이의 비슷함을 찾아 묶는 군집화는 비지도학습의 한 방법이다. N=3은 세 그룹을 만든다는 뜻이며, 그룹의 주제 이름은 결과를 읽은 사람이 붙인다. 같은 내용의 한국어 · 영어 문서가 함께 묶이는지도 살펴본다.
5. 문서를 분류하는 것과 요약하는 것은 어떻게 다른가? 분류는 IT처럼 정해진 종류를 고른다. 추출 요약은 원문에서 중요한 문장을 고르고, 생성 요약은 원문을 바탕으로 새 문장을 만든다. 요약은 문장이 자연스러운지뿐 아니라 핵심 내용이 빠지거나 사실이 바뀌지 않았는지도 확인한다.
6. 배운 문서를 잘 맞히면 좋은 모델인가? 처음 보는 문서에도 잘 적용하는 능력을 일반화라고 한다. 학습 문서에 지나치게 맞춰 새 문서에서 나빠지는 현상은 과적합이다. 이를 확인하려고 학습에 쓸 자료, 방법을 고를 검증 자료, 마지막 확인에 쓸 최종 평가 자료를 나눈다. 원문 100개를 60 · 20 · 20개로 나누는 설명용 예제로 역할을 익힌다. 비율은 고정 규칙이 아니며, 같은 원문의 복사본 · 조각 · 번역문이 서로 다른 자료에 섞이면 평가가 실제보다 좋아 보일 수 있음을 배운다.
7. 이미 학습된 모델을 쓰는 것과 더 학습시키는 것은 어떻게 다른가? 많은 자료로 미리 배우는 과정이 사전학습이다. 그 모델을 내 작업의 자료로 더 조정하는 과정이 추가학습이다. 기존 모델에 ‘요약해 줘’ 라고 요청하는 것과, 문서 · 요약 예시로 모델의 가중치를 바꾸는 일은 다르다. 가중치는 파라미터의 한 종류이며, 추가학습 후에도 실제로 좋아졌는지 따로 평가해야 한다.

어떻게 연습하나요? 종이와 메모장으로 다음 활동을 한다. Python으로 같은 계산을 실행하는 실습은 선택 사항이다.

- 학습·추론·평가 구분하기: 정답이 붙은 짧은 문서들에서 단어 점수를 구한다. 새 문서의 점수를 더해 IT · 스포츠를 예측하고, 맞힌 경우와 틀린 경우의 이유를 설명한다.
- 분류와 군집화 비교하기: 문서 30개에 정답 종류를 붙여 보는 활동을 한다. 이어서 별도의 한 · 영 문서 8개를 정답 라벨 없이 두 그룹과 세 그룹으로 묶어 보고, 묶은 뒤 그룹 이름을 붙인다.
- 분류와 요약 비교하기: 같은 문서에 종류를 붙이고, 중요한 원문 문장을 고르고, 한 문장으로 다시 요약한다. 세 결과가 어떻게 다른지 비교하고 요약에서 빠진 내용과 바뀐 사실을 찾는다.

완료 기준: 다음 질문에 예를 들어 답할 수 있으면 Chapter 2로 넘어간다.

- AI · 머신러닝 · 딥러닝은 어떤 관계이고, 작은 문서 분류 모델의 데이터 · 특성 · 파라미터는 각각 무엇인가?
- 단어 점수를 구할 때와 그 점수로 새 문서를 분류할 때 무엇이 다른가?
- 정답 종류를 맞히는 분류와 비슷한 문서를 모으는 군집화는 어떻게 다른가? N=3만 정하면 그룹 이름도 정해지는가?
- 추출 요약과 생성 요약은 무엇을 출력하며, 올바른 요약인지 어떻게 확인하는가?
- 왜 처음 보는 문서로 확인해야 하며, 검증 자료와 최종 평가 자료를 따로 두는가?
- 기존 모델에 요약을 요청하는 것과 예시 자료로 추가학습하는 것은 어떻게 다른가?

이 Chapter의 실습은 기본 개념을 이해하기 위한 작은 예제다. 실제 문서 요약 · 군집화 모델 설계는 뒤의 Chapter에서 배우며, Android 연결과 앱 기능 설계는 후속 POC에서 다룬다.

Chapter 2. Python·NumPy와 문서 데이터 처리

예정 PDF: Python·NumPy와_문서_데이터_처리.pdf · 학습 전

배우는 목적: 문서를 읽고 정리하며, 모델이 계산할 수 있는 데이터와 배열을 준비한다.

이론 범위: Python 변수 · 함수 · 리스트 · 딕셔너리 · 파일 읽기와 실행 환경을 익힌다. 추가 기능 묶음인 패키지, 숫자 배열을 다루는 NumPy, 배열의 크기 · 모양(Shape), 원소 고르기(인덱싱), 간단한 집계를 배운다. TXT · PDF 글자 추출, 계산에 맞게 입력을 정리하는 전처리와 문장 분리도 연습한다.

이해할 원리: 파일에서 꺼낸 글자가 곧 모델 입력은 아니다. 문서 · 문장 · 숫자 배열로 바꾸면서 문서가 뒤섞이거나 핵심 내용이 빠지지 않는지 확인한다. 어떤 정보가 남고 사라지는지는 숫자 표현 방식에 따라 다르다. 학습 자료는 모델을 맞추는 데, 검증 자료는 설정을 고르는 데, 최종 평가 자료는 선택이 끝난 결과를 확인하는 데 사용한다.

작은 예제: 문서 여러 개를 목록으로 읽고 문장 수 · 길이를 구한다. 한 · 영 문장에서 줄바꿈 · 띄어쓰기 · 문장 경계를 확인하고 배열의 행 · 열이 무엇인지 설명한다.

단원 실습: 출처 · 언어 · 문서 ID를 기록하고 빈 입력 · 중복 · PDF 반복 머리말을 정리한다. 원문과 정리 결과를 비교하며 문단 경계를 유지한다. 군집을 맞추는 문서 묶음과 새 문서를 구분하고, 요약 추가학습용 자료는 학습 · 검증 · 최종 평가로 나눈다.

완료 기준: 정리한 문서를 다시 읽어 같은 배열을 만들고, 전처리 규칙과 데이터 분리 이유를 설명한다. 군집용 자료에 정답 카테고리 라벨을 붙이는 것을 필수로 삼지 않는다.

Chapter 3. 기초 수학과 전통적 머신러닝

예정 PDF: 기초_수학과_전통적_머신러닝.pdf · 학습 전

배우는 목적: 문서의 숫자 표현 · 유사성 · 군집 중심을 이해하고 간단한 비교 기준을 만든다.

이론 범위: 숫자 목록인 벡터, 이를 행 · 열로 모은 행렬, 평균 · 분산 · 거리와 벡터 방향의 비슷함을 재는 코사인 유사도를 배운다. 단어 빈도와 문서별로 두드러진 단어에 점수를 주는 TF-IDF, 평균 중심을 이용해 N개 그룹을 만드는 K-Means의 중심 · 배정 · 갱신, 문장 점수를 이용한 추출 요약을 익힌다. 작은 숫자로 직접 계산한다.

이해할 원리: TF-IDF는 한 문서에 자주 나오면서 전체 문서에는 흔하지 않은 단어를 두드러지게 표현한다. 준비한 문서 모음에서 어휘와 단어별 문서 빈도를 구해, 흔한 단어의 비중을 낮추는 값인 IDF를 계산한다. 새 문서에도 같은 어휘 · IDF를 적용한다. K-Means는 처음 정한 N개 중심에 가까운 문서를 배정하고, 각 그룹의 벡터 평균으로 중심을 다시 구하는 과정을 반복한다. 중심이 거의 변하지 않거나 정한 반복 한도에 도달하면 멈춘다. 초기 중심에 따라 결과가 달라질 수 있으며, 원하는 주제나 가장 좋은 묶음을 찾았다는 보장은 없다. 어떤 숫자 표현과 거리 기준을 쓰는지에 따라 '비슷한 문서'가 달라진다.

작은 예제: 2차원 점의 거리와 평균 중심을 손으로 구하고, 짧은 문서를 단어 숫자로 바꿔 비슷한 문서와 중요한 문장을 고른다.

단원 실습: 손 계산 뒤 scikit-learn으로 TF-IDF · K-Means를 실행한다. N과 초기값을 바꾸고 핵심 문장을 원문 순서로 표시한다. 어휘가 다른 한 · 영 문서가 의미보다 언어로 갈릴 수 있음을 관찰한다.

완료 기준: TF-IDF의 학습과 새 문서 변환을 구분하고, 중심을 고정해 새 문서를 배정한다. N · 초기값 · 전처리 변화의 영향을 설명한다. 알고리즘 전체의 직접 구현을 요구하지 않는다.

Chapter 4. 딥러닝 기초와 PyTorch

예정 PDF: 딥러닝_기초와_PyTorch.pdf · 학습 전

배우는 목적: 신경망을 만들고 학습시키는 도구인 PyTorch를 사용한다. 학습 코드를 읽고 검증 결과에 따라 설정을 조정하는 기초를 익힌다.

이론 범위: 숫자 배열인 Tensor와 그 모양(Shape), 가중치가 있는 계산 층들을 연결한 신경망을 배운다. 층의 계산값에 비선형 변환을 적용하는 활성화 함수, 입력에서 예측을 계산하는 순전파, 예측 오차를 수치화한 손실(Loss)을 익힌다. 가중치를 바꾸면 오차가 어떻게 달라지는지 나타내는 기울기(gradient), 이를 계산하는 자동미분, 가중치를 갱신하는 최적화 도구(optimizer)를 연결한다. 한 번에 처리하는 자료 수(batch size), 전체 학습 자료를 훑은 횟수(epoch), 갱신 크기를 조절하는 학습률을 익힌다. 학습 · 검증 모드, 과적합과 저장 · 재실행도 다룬다.

이해할 원리: 활성화 함수는 단순한 직선 관계만으로 표현하기 어려운 패턴을 신경망이 다루게 한다. 예측 → 손실 계산 → 기울기 계산 → 가중치 갱신을 반복하며 손실을 줄이는 방향을 찾는다. 손실에서 앞선 층 방향으로 미분값을 연결해 각 가중치의 기울기를 구하는 과정이 역전파이며, PyTorch의 자동미분 기능으로 수행한다. 학습 자료의 오차만 줄고 새 자료에서 나빠지는 과적합이 생길 수 있으므로 검증 결과를 따로 확인한다. 미분은 작은 숫자 변화가 오차를 어떻게 바꾸는지부터 이해한다.

작은 예제: 입력 → 예측 → 손실 → 기울기 계산 → 가중치 갱신 → 검증의 한 바퀴를 따라간다. 작은 지도학습 예제는 신경망 학습 원리를 익히기 위한 비교 실습이다.

단원 실습: 학습률 · 반복 횟수 · 배치 크기를 하나씩 바꾸며 학습 · 검증 오차를 기록한다. 모델을 저장 · 불러오고 학습에 쓰지 않은 자료의 결과를 확인한다.

완료 기준: 학습 코드의 각 단계와 과적합을 설명하고, 고정한 실행 조건에서 결과를 재현한다. 오차가 줄지 않을 때 입력 · 학습 설정 · 검증 자료를 점검한다.

Chapter 5. 자연어 처리와 사전학습 모델 이해

예정 PDF: 자연어_처리와_사전학습_모델_이해.pdf · 학습 전

배우는 목적: 사람이 쓰는 언어를 컴퓨터로 다루는 자연어 처리의 기초를 익힌다. 문서 임베딩 모델과 문장을 생성하는 요약 모델의 역할을 구분하고 적합한 후보를 선택한다.

이론 범위: 텍스트를 토큰이라는 처리 단위와 번호로 바꾸는 tokenizer를 익힌다. 시작 · 끝 등 역할을 알리는 특수 토큰, 길이를 채우는 padding, 한도를 넘는 부분을 자르는 truncation을 배운다. 문맥에 따라 토큰 사이의 관련성을 계산하는 Transformer, 서로 다른 언어의 의미도 벡터로 비교하도록 학습된 다국어 문장 임베딩, 토큰 · 문장 · 문서 벡터의 통합과 정규화, 긴 문서 분할을 다룬다.

이해할 원리: 사전학습 모델은 이미 많은 자료에서 구한 가중치를 가져와 사용한다. 임베딩 모델은 내용을 비교할 벡터를 만들고, 여기서 사용하는 생성 모델은 다음 토큰 후보를 계산하며 요약문을 만든다. 다국어 임베딩은 같은 뜻의 한 · 영 문장을 가까이 표현하도록 학습한 모델을 선택한다. 두 언어를 입력할 수 있다는 사실만으로 언어 간 비교 품질을 보장하지 않으므로 실제 문서로 확인한다. 여러 토큰 · 조각의 벡터를 합치는 방법도 결과에 영향을 준다. 정규화는 벡터의 원소 개수는 유지하면서 전체 크기를 일정하게 맞추는 것이다. 모델에 맞는 tokenizer가 필요하며, 잘린 부분의 정보는 입력에서 빠진다.

작은 예제: 같은 주제의 한 · 영 문서와 주제가 다른 문서의 벡터를 비교한다. 생성 모델로 짧은 문서를 요약하고, 임베딩 벡터가 요약문 자체는 아니라는 점을 확인한다.

단원 실습: 긴 문서를 나눠 문서 벡터로 합친다. 모델별 한 · 영 지원 · 입력 한도 · 라이선스 · 메모리 · 실행 도구 지원을 확인한다. 추가학습 전에 작은 입력으로 변환 · 기기 실행 가능성을 먼저 시험한다.

완료 기준: 전처리부터 출력까지의 흐름과 임베딩 · 생성 모델의 차이를 설명하고, 선택한 후보의 품질 · 기기 제약과 한계를 기록한다.

Chapter 6. 문서 임베딩과 비지도 군집화 설계

예정 PDF: 문서_임베딩과_비지도_군집화_설계.pdf · 학습 전

배우는 목적: 문서를 N개 카테고리로 묶는 모델의 표현 · 군집화 · 명명 · 갱신 절차를 설계한다.

이론 범위: 문서 벡터 통합 · 정규화, N과 처음 계산을 시작할 중심을 정하는 초기값, 반복 실행, 대표 문서 · 핵심어를 배운다. 같은 군집의 문서가 얼마나 가깝고 다른 군집과 얼마나 떨어져 있는지 살피는 실루엣 점수, 내용의 의미 검토, 새 문서 · 범위 밖 입력을 다룬다. N개 그룹과 자연스러운 주제 수가 같다고 가정하지 않는다.

이해할 원리: 문서의 숫자 표현과 중심이 정해지면 새 문서를 가까운 중심에 배정할 수 있다. K-Means는 다루려는 주제 밖의 문서도 기존 군집에 배정하므로 '모름' 처리는 따로 설계한다. 실루엣은 각 문서에서 같은 군집 안의 평균 거리와 다른 군집별 평균 거리 중 가장 작은 값을 비교한다. 점수는 -1~1 범위이며, 높을수록 사용한 거리 기준에서 군집이 잘 떨어져 있다는 뜻이다. 실루엣이 좋아도 원하는 주제로 묶였다는 보장은 없으므로 대표 문서를 읽어 확인한다.

작은 예제: 같은 N에서 TF-IDF와 임베딩을 비교하고, 같은 표현에서 초기값을 바꾼다. 실루엣은 2≤군집 수<문서 수인 조건을 확인하고 보조 지표로 사용한다.

단원 실습: 언어보다 주제로 묶이는지 대표 문서를 읽는다. 다시 학습하면 군집 번호가 바뀔 수 있으므로 문서가 함께 묶이는 관계를 비교한다. 중심 고정 후 새 문서 배정과 어울리지 않는 문서의 처리 · 군집 갱신 방안을 적는다.

완료 기준: 선택 이유와 실패 사례를 설명하고 N · 표현 · 평가 조건을 고정해 재현할 수 있으면, Chapter 1~6의 준비 상태를 확인한 뒤 POC A로 진행한다.

Chapter 7. 문서 요약 모델 설계와 추가학습

예정 PDF: 문서_요약_모델_설계와_추가학습.pdf · 학습 전

배우는 목적: 요약 모델 · 입력 처리 · 평가를 설계하고 한 · 영 요약의 품질과 실행 비용을 판단한다.

이론 범위: 원문 문장을 고르는 추출 요약과 새 문장을 만드는 생성 요약을 비교한다. 작업 · 출력 조건을 전달하는 지시인 프롬프트, 출력 길이와 생성 설정, 긴 문서 분할 · 조각 요약 · 최종 통합을 배운다. 원문에 없는 내용과 누락을 찾고, 사람이 작성한 참고 요약과 비교하는 점수와 직접 검토를 함께 사용한다.

이해할 원리: 생성 요약은 원문과 앞서 만든 출력을 바탕으로 다음 토큰을 이어 만든다. 자연스러운 표현을 만들어도 날짜 · 수치 · 인물 관계를 잘못 쓸 수 있다. 프롬프트나 출력 설정을 바꾸는 것은 입력 · 실행 조건의 변경이며 모델 가중치를 학습하는 것과 다르다. 문서를 나눠 요약할 때는 조각별 정보와 전체 문맥을 다시 합쳐야 한다. 참고 요약과 비슷하다는 점수만으로 원문의 사실을 지켰다고 판단하지 않는다.

작은 예제: 짧은 문서를 원문 언어로 요약하고 프롬프트 · 출력 길이를 하나씩 바꾼다. 자연스러운 문장과 사실에 맞는 문장이 다른 기준임을 확인한다.

단원 실습: 짧은 문서 → 설정 변경 → 긴 문서 분할 · 통합 순서로 진행한다. 문서 앞 · 중간 · 끝의 핵심 내용 보존과 반복 · 누락을 검토한다. 같은 문서에서 추출 · 생성 요약의 품질과 비용을 비교한다.

완료 기준: 모델 · 처리 흐름 · 평가표 · 실패 예시를 재현하고 설명할 수 있을 때 POC B로 진행한다. 요약문 작성 예제를 따라 하는 단계와 모델 선택 · 평가 단계를 구분한다.

선택 심화 · 추가학습 중급: 문서 – 요약 쌍을 준비하고 학습 · 검증 · 최종 평가 자료를 분리한다. 이미 학습된 모델을 목적에 맞는 자료로 더 학습하는 추가학습을 수행한다. 기반 가중치는 고정하고 작은 가중치만 학습하는 LoRA도 선택할 수 있다. LoRA는 큰 가중치의 수정량을 두 작은 행렬의 곱으로 표현해 학습할 가중치 수와 갱신 정보의 메모리를 줄인다. 기반 모델도 필요하므로 전체 실행 모델이 자동으로 작아지는 방법은 아니다. 원본 대비 개선 · 악화와 비용을 확인하며, 용어 이해나 코드 실행만으로 완료하지 않는다. 학습 결과의 기기 배포 가능성도 먼저 확인한다.

Chapter 8. Android 온디바이스 배포와 경량화

예정 PDF: Android_온디바이스_배포와_경량화.pdf · 학습 전

배우는 목적: 선택한 군집 · 요약 경로를 기기에서 재현하고 품질 · 속도 · 메모리 제약에 맞춘다.

이론 범위: 모델 · tokenizer · 어휘 · IDF · 군집 중심을 저장하고 전처리 · 특수 토큰 · padding · 분할 · 정규화 조건을 맞춘다. 모델의 실행 형식을 바꾸는 변환, 실제 계산을 수행하는 실행 도구인 ONNX Runtime의 CPU 실행, 숫자를 더 적은 비트로 표현하는 양자화를 배운다. 비동기 실행 · 취소 · 자원 해제 · 오류 상태를 다루며, 생성 모델을 지원하는 실행 도구는 후보 선정 단계에서 확인한다.

이해할 원리: 같은 모델이라도 입력을 다르게 만들면 결과가 달라질 수 있으므로 PC와 앱의 처리 조건을 맞춘다. 양자화는 가중치 등의 숫자를 적은 비트의 단계로 근사해 저장 부담을 줄이며, 이때 생기는 오차

가 품질에 영향을 줄 수 있다. 실행 메모리 · 속도 개선은 기기와 실행 도구가 해당 계산을 어떻게 지원하는지에 따라 다르다. 파일 크기만으로 판단하지 않고 실제 실행에서 확인한다.

작은 예제: 동일한 배포 모델과 전처리 조건으로 PC · Android의 입력 · 중간 벡터 · 군집 배정 · 추출 요약을 비교한다. 벡터는 정한 허용 오차로 확인한다. 원본 → 변환 → 양자화의 정밀도 · 품질 변화는 별도로 평가한다.

단원 실습: 비행기 모드와 한 · 영 문서로 실행 · 취소 · 재실행을 확인한다. 같은 입력 길이 · 출력 조건에서 최초 로딩과 준비 후 실행 시간을 나누고, 프로세스 최대 메모리와 모델 · tokenizer 파일 크기를 기록한다. 앱 연결은 에뮬레이터, 성능 판단은 실기기로 검증한다.

완료 기준: 동일한 배포 모델의 PC 기준과 군집 배정 · 추출 요약 결과를 대조하고, 허용 오차 · 차이의 원인과 품질 · 지연 · 메모리를 설명할 수 있을 때 POC C로 진행한다. 생성형 요약은 실기기 지원 · 자원 · 품질을 확인해 적용하고, 부족하면 측정 근거와 추출 요약 대체 경로를 남긴다.

모델별 POC와 Android 통합 POC

모든 POC는 앞서 정한 공통 진입 조건을 만족한 뒤 진행한다. 비교 자료 · 목표 · 판정 기준을 먼저 정하고 실험 중 바꾼 조건을 기록한다. 실제 문서는 사용 권한이 있는 자료를 사용하며 개인 정보가 필요하면 제거한다.

POC	진입 시점	핵심 결과물
A · 비지도 군집 모델	Chapter 1~6 이론·단원 실습·평가 확인 후	PC 군집 시제품, 평가표·설계안
B · 문서 요약 모델	Chapter 7의 이론·단원 실습·평가 확인 후	PC 요약 시제품, 평가표·설계안
C · Android 통합	A·B와 Chapter 8 단원 실습 완료 후	오프라인 통합 앱, PC 대조·측정표

POC A · 비지도 군집 모델 설계 검증

입력: 주제와 언어 구성을 기록한 문서 묶음, 고정한 N, 모델을 맞추는 데 쓰지 않은 새 문서.

진행: 같은 문서와 N으로 TF-IDF · 다국어 임베딩을 비교한다. 여러 초기값에서 문서 관계와 대표 문서를 검토하고 그룹의 의미 · 이름을 정한다. 선택한 표현과 중심을 저장한 뒤 새 문서를 배정한다.

완료: 재실행 가능한 코드 · 전처리 · 모델 설정 · 중심을 남긴다. 언어별 · 주제별 군집 품질, 안정성, 범위 밖 문서와 실패 예시를 설명하고 선택 이유를 설계안에 적는다. 그룹 수를 맞췄다는 사실만으로 완료하지 않는다.

POC B · 문서 요약 모델 설계 검증

입력: 학습에 사용하지 않은 한 · 영 짧은 문서와 긴 문서, 사람이 정리한 핵심 내용 또는 참고 요약.

진행: 동일한 문서에서 추출 · 생성 요약을 비교한다. 원문 언어, 입력 분할 · 최종 통합, 출력 길이 · 모델 설정을 고정한다. 사실성 · 핵심 내용 보존 · 누락 · 반복 · 처리 시간을 평가한다.

완료: 요약 코드 · 모델 · tokenizer · 설정과 평가표를 저장한다. 좋은 결과와 실패 예시를 포함한 설계안을 남기고 다른 사람이 같은 문서로 재실행할 수 있게 한다. 추가학습을 했다면 원본과 학습 후 모델을 같은 최종 평가 자료로 비교한다.

POC C · Android 통합 검증

입력: A · B에서 선택한 모델 · 처리 흐름과 고정한 한 · 영 평가 문서. 군집은 준비된 중심에 새 문서를 배정하는 방식을 기본으로 한다.

Android 연결 설명: 이 단계에서 앱 코드 · 모델 · 실행 도구의 역할과 학습 · 추론의 위치를 연결해 이해한다. PC · Colab에서 모델과 군집을 준비하고, 모델 · tokenizer · 전처리 설정 · 군집 중심을 호환되는 묶음으로 앱에 배포한다. 앱은 문서 읽기 · 입력 준비 · 실행 요청 · 결과 표시를, 실행 도구는 모델 계산을 담당한다. 문서 분석을 휴대폰 안에서 수행하는 구성이 온디바이스 AI다. 모델 다운로드와 사용자 문서를 서버에서 분석하는 것은 구분한다.



그림 2. POC C의 Android 연결. 모델·군집을 준비하고, 휴대폰에서는 준비된 기준으로 문서를 분석한다.

기능 명세 실습: 입력 파일 · 언어, 요약 출력 형태, 문서 모음 · N, 그룹 내용 검토 · 이름, 실행 위치, 빈 입력 · 여러 주제 처리 방향을 적는다. PC에서 표현 모델과 N개 중심을 준비한 뒤 앱에서 새 문서를 같은 방식으로 표현하고 가까운 중심에 배정하는 흐름을 설명한다. 그룹 번호는 임시 표시이며, 대표 문서와 핵심어를 검토해 이름을 정한다. 기기 자원과 미지원 입력의 처리도 명세에 포함한다.

진행: 문서 선택 → 텍스트 추출 → 군집 배정 · 요약 → 결과 표시를 연결한다. 오프라인에서 동일 배포 모델의 PC 기준과 군집 배정 · 추출 요약을 대조하고 차이를 설명한다. 취소 · 연속 실행과 실기기 자원을 측정하며 생성형 요약은 기기에 적합한 경로를 별도로 시험한다.

완료: 대상 기기 · Android 버전 · 입출력 조건 · 로딩/실행 시간 · 최대 메모리 · 파일 크기를 기록한다. 두 기능의 품질과 실패 처리를 설명하고, 생성 모델을 적용하거나 대체한 근거를 남긴다. 기기마다 동일한 생성 속도를 가정하지 않는다.

기본 과정 평가·기록과 도달 기준

- 자료 · 전처리 · 모델 버전 · 초기값 · 실행 조건을 기록하고 고정 자료로 비교한다. 모델 선택에 쓰는 자료와 최종 평가 자료를 구분하며, 같은 원문의 복제 · 번역본이 양쪽에 섞이지 않게 확인한다.
- 군집은 대표 문서 · 문서 관계 · 안정성과 점수를 함께 검토한다. 군집 번호를 정답 카테고리처럼 취급하지 않으며, 한 · 영 문서가 언어보다 내용으로 묶이는지 확인한다.
- 요약은 언어별 사실성 · 핵심 내용 보존 · 누락을 직접 검토한다. 자동 점수만으로 사실성을 판단하지 않는다. 추가학습 · 최종 평가 문서는 분리한다.
- 이론을 설명하고, 작은 실습을 독립적으로 바꾸며, POC에서 대안을 비교 · 선택하고, Android에서 두 기능의 실행 근거를 제시하면 기본 활용 · 설계 중급을 완료한다.
- 요약 추가학습까지 수행했다면 데이터 준비 · 학습 · 검증 · 원본 대비 평가 · 배포 확인을 별도로 기록해 선택 심화 완료를 구분한다.

고급 과정 안내 · 학습 예정

배우는 목적: 기존 모델을 실행하는 수준에서 더 나아가, 어떤 원인으로 품질이 떨어지거나 기기 비용이 커지는지 실험으로 찾고 개선한다. 최종 목표는 같은 한국어 · 영어 문서 요약과 N개 그룹의 비지도 군집화이며, 대규모 사전학습이나 모든 기기의 가속기 지원을 필수로 삼지 않는다.

진입 조건: 기본 과정 Chapter 1~8의 이론 · 실습과 POC A~C를 마친다. 입력 처리 · 모델 선택 · 평가 · 실기기 측정 결과를 자신의 말로 설명하고 재실행할 수 있어야 한다. Chapter 7의 선택 추가학습을 건너뛰었다면 Chapter 10 전에 작은 요약 추가학습 실험을 먼저 수행한다.

학습 순서: Chapter 9 → Chapter 10 · 11 → Chapter 12 → Chapter 13 → Chapter 14 → 고급 종합 POC D로 진행한다. Chapter 10과 11은 각자 필요한 선수 개념을 익힌 뒤 병행할 수 있다. 모든 고급 Chapter도 쉬운 설명 → 작은 계산 · 예제 → 단원 실습 → 평가 확인 순서를 따른다.

학습 방식의 구분: 군집을 만들 때 사람이 붙인 정답 카테고리 라벨을 필수로 사용하지 않는다. 요약 학습에는 문서 – 요약 쌍을, 표현 학습에는 문장 자체에서 만든 목표를, 증류에는 교사 모델의 출력을 사용할 수 있다. 각 실험이 무엇을 학습 신호로 쓰는지 기록하며 모든 과정을 무라벨 학습이라고 부르지 않는다.

환경과 비교 기준: 학습 · 증류는 PC나 클라우드 컴퓨터에서 작은 모델 · 자료로 시작한다. 필요한 GPU 메모리와 비용을 먼저 확인하고, Android로 변환 가능한지도 작은 입력으로 시험한다. Chapter 9에서 비교 자료 · 품질 · 자원 목표를 정해 이후 실습에 계속 사용한다. 최종 평가 자료는 방법을 고르는 데 반복 사용하지 않는다.

Chapter 9. 수학·통계와 실험 설계 심화

예정 PDF: 수학·통계와_실험_설계_심화.pdf · 학습 전

선수 학습: 기본 과정 완료, 특히 Chapter 3 · 4의 벡터 · 미분 · 학습 과정 이해.

배우는 목적: 모델의 학습 원리와 실험의 변동을 이해하고, 개선을 판단할 공통 기준을 세운다.

이론 범위: 행렬 곱과 미분의 연결, 여러 계산의 미분을 연결하는 연쇄법칙, 확률 · 조건부 확률과 확률분포를 배운다. 정답에 준 확률이 낮을수록 벌점을 크게 주는 교차 엔트로피 손실을 익힌다. 기울기의 반대 방향으로 가중치를 조금씩 바꾸는 경사하강법과, 기울기의 평균 · 크기 추정으로 갱신을 조절하는 Adam

을 비교한다. 표본 · 평균 · 변동, 자료를 다시 뽑아 결과 변동을 살피는 부트스트랩, 비교 조건을 고정하는 실험 설계도 다룬다.

이해할 원리: 손실은 학습이 줄이려는 수치이며 사용자가 느끼는 품질과 같지 않을 수 있다. 같은 방법도 자료와 초기값에 따라 결과가 달라지므로 한 번의 좋은 점수만으로 개선을 판단하지 않는다. 일부 기능만 켜고 끄는 비교 실험으로 어느 변경이 효과를 냈는지 확인한다.

작은 예제: 작은 행렬의 곱과 한 가중치의 갱신을 계산한다. 정답에 준 확률을 바꿔 손실을 비교하고, 같은 문서 묶음에서 뽑은 표본에 따라 평가 점수가 달라지는 모습을 확인한다.

단원 실습: POC A~C의 모델을 비교 기준으로 고정한다. 한 · 영, 주제, 길이별 평가표와 오류 유형을 정하고 여러 초기값으로 반복한다. 원문 단위로 자료를 나눠 같은 문서의 조각 · 번역본이 평가에 섞이지 않게 한다. 요약의 사실성, 군집의 의미 · 안정성, 기기 시간 · 메모리 목표를 미리 적는다.

완료 기준: 확률 · 손실 · 가중치 갱신을 작은 수치로 설명하고, 비교 조건 · 결과 변동 · 실패 사례를 포함한 실험 계획서를 만든다. 반복 횟수가 적거나 평가 자료가 좁을 때 결론의 한계도 설명한다.

Chapter 10. Transformer와 문서 요약 추가학습 심화

예정 PDF: Transformer와_문서_요약_추가학습_심화.pdf · 학습 전

선수 학습: Chapter 5 · 7 · 9. Chapter 7의 작은 요약 추가학습과 원본 대비 평가 완료.

배우는 목적: 요약 모델 내부 계산을 이해하고, 데이터 · 학습 방식 · 긴 문서 처리 중 무엇을 바꿀지 근거를 갖고 결정한다.

이론 범위: 토큰 사이의 관련성을 계산하는 attention에서 비교할 정보인 Q · K와 합칠 정보인 V를 배운다. 점수를 비율로 바꾸는 softmax, 여러 관점의 관련성을 계산하는 multi-head attention, 위치 정보와 토큰을 가리는 마스크도 다룬다. 토큰마다 계산을 적용하는 신경망(FFN), 앞선 값을 더하는 잔차 연결, 특성의 평균 · 분산을 기준으로 정리하는 LayerNorm을 살핀다. 입력을 읽는 encoder와 출력을 만드는 decoder, 토큰별 손실, 전체 가중치 추가학습과 LoRA를 비교한다. 양자화한 기반 가중치를 고정하고 LoRA를 학습하는 QLoRA는 선택 심화로 둔다. 기반 가중치의 저장 부담과 학습할 가중치 수를 함께 줄여 학습 메모리를 아끼는 방법이다.

이해할 원리: attention은 관련성 점수를 비율로 바꿔 토큰 정보를 섞으며 문맥을 표현한다. LayerNorm은 Chapter 5의 문서 벡터 크기 맞추기와 다른 계산이다. 학습 때 이전 정답 토큰을 주는 조건과, 추론 때 이전 생성 토큰을 쓰는 조건은 달라 오류가 이어질 수 있다. 긴 문서를 나눠 요약하면 조각의 사실과 전체 관계가 누락될 수 있어 최종 통합을 따로 검토한다. 학습 메모리를 줄이는 방법과 Android에서 실행할 모델 형식은 구분한다. QLoRA의 학습 형식을 기기에서 그대로 지원한다고 가정하지 않는다.

작은 예제: 토큰 세 개의 attention 점수와 가중합을 계산하고 마스크 유무를 비교한다. 같은 문서의 요약에서 잘못 바뀐 날짜 · 숫자와 누락된 근거 문장을 찾는다.

단원 실습: 작은 요약 모델에서 문서 – 요약 쌍의 품질과 언어별 구성을 확인한다. 가능한 자원 안에서 전체 추가학습과 LoRA를 비교하고, 학습률 · 학습 대상 · 문서 분할 중 한 조건씩 바꾼다. QLoRA는 필요한 경우 시험한다. 보관한 학습 상태에서 재개하고, 후보 선정에는 검증 자료만 사용한다. 최종 모델은 별도 자료에서 한 · 영 사실성 · 누락 · 반복과 변환 가능성을 확인한다.

완료 기준: attention부터 손실 · 갱신까지의 흐름, 선택한 학습 방식과 데이터의 영향을 설명한다. 원본 대비 개선과 악화, 학습 비용, 긴 문서의 한계, 기기 배포 가능성을 재현 가능한 보고서에 남긴다.

Chapter 11. 문서 임베딩과 비지도 군집화 심화

예정 PDF: 문서_임베딩과_비지도_군집화_심화.pdf · 학습 전

선수 학습: Chapter 5 · 6 · 9. Transformer 계산은 Chapter 10의 attention 부분까지 이해.

배우는 목적: 사전학습 임베딩을 내 문서에 맞춰 조정하고 군집 갱신 방법을 개선한다.

이론 범위: 내 분야의 문서로 표현을 조정하는 도메인 적응, 일부를 지운 문장에서 원문을 복원하며 표현을 배우는 TSDAE를 배운다. 관련 있는 쌍은 가깝게, 관련 없는 쌍은 멀게 만드는 대조 학습과 학습 쌍을 고르는 기준도 다룬다. 문서 벡터 통합 · 차원 축소, 고정 N 군집과 밀도 기반 군집의 차이, 새 주제 · 범위 밖 문서 · 군집 갱신을 비교한다. 밀도 기반 방법은 비교용이며 N개 결과를 보장하지 않는다.

이해할 원리: TSDAE는 손상한 문장을 벡터로 압축한 뒤 원문을 복원하도록 학습한다. 원래 문장 자체가 학습 목표이므로 사람이 붙인 카테고리 정답은 필요하지 않다. 학습 후에는 문장을 벡터로 바꾸는 부분을 사용한다. 표현 모델이 달라지면 문서 사이의 거리도 달라진다. 학습 문장 복원이 좋아졌다고 군집 의미가 반드시 좋아지는 것은 아니다. 다른 문장을 모두 다른 주제로 보고 대조 학습하면 오류가 생길 수 있다. 임베딩을 교체하면 새 표현에 맞춰 군집 중심을 다시 계산한다. 다시 묶은 그룹의 번호가 같아도 예전 주제와 같다고 가정하지 않는다.

작은 예제: '배터리 충전 시간이 줄었다'에서 일부 단어를 지운 입력으로 원문을 복원하는 학습 목표를 만든다. 같은 주제의 한 · 영 문서와, 단어는 비슷하지만 주제가 다른 문서를 비교한다. 표현 변경 전후의 묶음 · 대표 문서를 살피고, N을 고정하는 방법과 그룹 수를 자동으로 찾는 방법을 비교한다.

단원 실습: 사람의 카테고리 정답 라벨 없이 문장 자체에서 학습 목표를 만드는 작은 표현 학습을 수행한다. 원본 · 조정 모델의 한 · 영 군집 의미와 안정성을 비교하고 N개 군집을 구성한다. 2차원 그림은 참고로만 사용하며 원래 벡터에서도 평가한다. 범위 밖 문서의 보류 기준을 검증 자료로 정하고, 새 문서 추가 후 재군집화 · 이름 연결을 확인한다.

완료 기준: 학습에 사용한 신호와 군집 평가를 구분하고 표현 변경의 효과 · 한계를 설명한다. N개 그룹, 범위 밖 처리, 중심 재계산, 사람이 검토하는 그룹 이름 갱신을 일관된 절차로 제시한다.

Chapter 12. 지식 증류와 모델 경량화 심화

예정 PDF: 지식_증류와_모델_경량화_심화.pdf · 학습 전

선수 학습: Chapter 8 · 9와 Chapter 10 · 11의 학습 · 평가 실습 완료.

배우는 목적: 품질과 모델 크기의 균형을 찾고, 압축 효과를 실제 기기 비용으로 판단한다.

이론 범위: 큰 교사 모델의 출력 · 표현을 작은 학생 모델이 배우는 지식 증류를 익힌다. 학습 후 숫자 표현을 줄이는 PTQ와 양자화 오차를 고려하며 학습하는 QAT를 비교한다. 일부 가중치 · 구조를 줄이는 프루닝도 원리와 실행 도구 지원을 살핀다. 모든 방법을 동시에 적용하지 않으며 증류와 PTQ를 먼저 실습하고 QAT · 프루닝 구현은 필요에 따라 선택한다.

이해할 원리: 증류는 학생 모델을 새로 학습하는 과정이고, LoRA처럼 학습할 가중치 수를 줄이는 것과 목적이 다르다. 임베딩은 차원을 맞춘 교사 · 학생 벡터의 차이를, 생성 모델은 교사가 만든 요약을 예측하는 오차 등을 학습 목표로 삼을 수 있다. 선택한 목표와 출력 형식을 함께 확인한다. 작은 임베딩 모델을 증류한 뒤 군집화하면 N개 그룹이라는 목표를 유지할 수 있다. 군집 번호를 정답으로 분류기를 학습하면 학생은 지도학습 분류기가 되므로 별도 방법으로 구분한다. 교사의 오류도 전달될 수 있어 정답으로 맹신하지 않는다.

작은 예제: 같은 문서에서 교사와 학생의 벡터 관계를 비교한다. 숫자를 적은 단계로 반올림했을 때 오차를 계산하고, 파일이 작아져도 실행이 빨라지지 않는 경우를 살펴본다.

단원 실습: 작은 임베딩 모델이나 요약 모델 하나를 대상으로 증류한다. 이후 원본 · 학생 · PTQ 모델을 같은 조건에서 비교한다. 정적 PTQ는 실제 입력을 대표하는 한 · 영 보정 자료로 숫자 범위를 정하며 최종 평가 자료와 분리한다. 품질 손실이 크면 원래 학습 도구에서 QAT를 검토한다. 임베딩 변경 후에는 각 모델에 맞게 중심을 다시 계산한다.

완료 기준: 한 · 영 품질 · 군집 의미 · 파일 크기 · 실기기 메모리 · 시간을 비교해 채택하거나 제외한 이유를 설명한다. 사용한 학습 신호 · 압축 설정과 실행 도구 지원을 기록하며, 크기 감소만으로 성공을 선언하지 않는다.

Chapter 13. Android 추론 성능 최적화

예정 PDF: Android_추론_성능_최적화.pdf · 학습 전

선수 학습: Chapter 8의 실기기 POC C와 Chapter 12의 배포 가능한 모델 비교 완료.

배우는 목적: 느린 단계와 메모리 사용 원인을 측정하고 대상 휴대폰에서 효과가 있는 최적화를 선택한다.

이론 범위: 단계별 시간 · 자원을 측정하는 프로파일링, CPU 스레드 · 입력 길이 · 버퍼 재사용, GPU · NPU로 계산을 맡기는 가속을 배운다. 지원하지 않는 계산이 CPU로 돌아오는 fallback, 첫 실행의 준비 비용과 캐시, 모델 가중치 · 중간 계산값의 메모리를 구분한다. 생성 모델에서는 이전 토큰의 계산값을 보관하는 KV 캐시의 속도 · 메모리 교환 관계도 다룬다.

이해할 원리: 가속기를 켰다는 설정과 실제 계산이 가속기에서 실행됐다는 사실은 다르다. 자료 이동 · 준비 비용과 CPU에 남은 계산 때문에 오히려 느려질 수 있다. 생성 모델의 입력 처리와 토큰을 하나씩 만드는 단계는 비용이 다르며, 입력 · 출력 길이가 측정 결과를 바꾼다.

작은 예제: 문서 읽기 · 토큰 변환 · 모델 계산 · 결과 표시 시간을 나누어 느린 단계를 찾는다. 입력 길이와 스레드 수를 하나씩 바꾸고, 첫 실행과 준비 후 실행을 비교한다.

단원 실습: CPU를 기준으로 지원되는 GPU · NPU 경로를 시험하고 로그 · 프로파일러로 실제 실행 위치와 fallback을 확인한다. 같은 입력 · 출력 조건에서 전체 처리 시간 · 최대 메모리 · 연속 실행의 발열 · 전력 영향을 실기기로 기록한다. 전력 측정 방법과 한계도 적는다. 지원 기기가 없으면 CPU 최적화를 수행하고 해당 가속기 검증은 미완료로 남긴다.

완료 기준: 원인 측정 → 한 조건 변경 → 품질 · 자원 재측정의 과정을 재현한다. 대상 기기 · 실행 도구 · 정밀도 · 지원 조건과 실제 개선을 제시하고, 지원되지 않거나 더 느린 경로를 제외한 근거를 남긴다.

Chapter 14. 품질 평가와 모델 운영

예정 PDF: 품질_평가와_모델_운영.pdf · 학습 전

선수 학습: Chapter 9에서 정한 평가 기준과 Chapter 10~13의 실험 · 기기 결과 확보.

배우는 목적: 앞선 평가를 통합하고, 모델 교체 뒤에도 앱의 품질과 동작을 유지할 절차를 만든다.

이론 범위: 변경 후 기존 기능이 나빠지는지 확인하는 회귀 평가, 사람 간 평가 기준 맞추기, 입력 문서의 주제 · 언어 구성이 변하는 데이터 변화, 실험 · 모델 버전 관리를 배운다. 모델 · tokenizer · 전처리 · 군집 중심 · 그룹 이름을 호환되는 묶음으로 배포하고, 문제가 생기면 이전 묶음으로 되돌리는 복구도 다룬다. 이러한 개발 · 평가 · 배포 · 관리를 연결하는 실무를 MLOps라고 한다. 실험 조건과 모델을 함께 기록하고,

평가를 통과한 묶음을 배포한 뒤 동작을 확인하는 절차를 익힌다. 이 과정은 온디바이스 앱에 필요한 범위로 시작한다.

이해할 원리: 파일 하나가 정상이어도 모델과 tokenizer · 중심의 기준이 어긋나면 결과가 달라진다. 임베딩을 바꾸거나 재군집화하면 중심과 이름 연결도 검토해야 한다. 입력 구성의 변화는 재평가할 신호이며, 그 자체가 자동 재학습을 뜻하지 않는다.

작은 예제: 같은 문서를 원본 · 새 모델로 실행해 품질 차이를 찾는다. 이전 중심을 잘못 조합한 경우를 확인하고 호환되는 묶음으로 복구한다. 같은 요약에 서로 다른 평가를 내렸다면 원문 근거로 기준을 맞춘다.

단원 실습: 한 · 영 · 길이 · 주제별 고정 회귀 자료와 새 문서를 함께 사용하되 최종 평가의 역할은 구분한다. 빈 입력 · 잘못된 PDF · 취소 · 메모리 부족 · 모델 교체 실패를 검증한다. 버전과 설정만으로 결과를 다시 만들고, 교체 실패 시 이전 모델 묶음으로 복구한다. 문서 원문을 서버로 보내지 않는 평가 · 기록 방식을 기본으로 설계한다.

완료 기준: 품질 허용 기준, 교체 전 확인 사항, 호환 버전, 복구 · 재평가 조건을 문서와 실행 결과로 제시한다. 평가를 처음 시작하는 단계가 아니라 Chapter 9~13의 결과를 통합하는 단계임을 설명할 수 있을 때 POC D로 진행한다.

고급 종합 POC D · 개선 모델과 앱 검증 예정

진입 조건: Chapter 9~14의 필요한 이론 · 예제 · 단원 실습 · 평가를 모두 마친다. 선택 항목인 QLoRA · QAT · 프루닝과 특정 가속기는 적용 여부와 미검증 범위를 적는다. 기본 POC A~C의 결과와 비교할 자료 · 기기 · 품질 · 자원 목표를 고정한다.

입력: 기존 기준 모델, 개선한 요약 · 문서 표현 모델과 그중 경량화한 모델, 각 표현에 맞춘 N개 중심, 보관한 한 · 영 평가 문서와 대상 실기기.

진행: 기준 모델 → 학습 · 표현 개선 → 경량화 → 기기 최적화의 효과를 단계별로 비교한다. 원문에 맞는 요약, 내용별 군집 의미 · 안정성 · 범위 밖 처리, 전체 시간 · 메모리 · 연속 실행을 확인한다. 마지막에 모델 묶음을 교체하고 오류 상황과 이전 버전 복구를 검증한다.

완료 기준: 모든 점수가 좋아져야 한다고 가정하지 않고 사전에 정한 품질 · 자원 목표로 개선안을 채택하거나 제외한다. 최소 한 대상 실기기에서 오프라인 실행과 모델 교체 · 복구를 재현하고, 데이터 · 학습 신호 · 코드 · 설정 · 평가 · 측정을 연결한 최종 설계 보고서를 남긴다. 비교한 기법 수나 특정 가속기 사용 여부만으로 고급 과정 완료를 판단하지 않는다.